

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное
учреждение высшего образования

Национальный исследовательский университет
«Высшая школа экономики»

Факультет гуманитарных наук
Образовательная программа
«Фундаментальная и компьютерная лингвистика»

КУРСОВАЯ РАБОТА

Методология сравнения предсказания слов у людей и больших
языковых моделей в cloze-тесте

Methodology of Comparing Word Prediction by People and Large
Language Models in Cloze-test

Студентка 3 курса
группы №231
Монина Вера Евгеньевна
Научный руководитель:
Выренкова Анастасия
Сергеевна, Доцент

Москва, 2026 г.

Благодарности

Данная курсовая работа была выполнена в рамках совместного проекта с Центром языка и мозга НИУ ВШЭ, посвящённого исследованию предсказуемости и больших языковых моделей. Автор выражает искреннюю признательность Серикову Олегу Алексеевичу за руководство технической частью исследования, Пихтину Андрею Андреевичу — за помощь в разработке кода для извлечения предсказаний языковых моделей, а также Слюсарь Наталье Анатольевне — за ценные методологические рекомендации.

1. Введение	5
2. Предсказуемость в психолингвистике	6
2.1 Статические и динамические факторы обработки слова	6
2.2 Теория surprisal	7
2.3 Cloze-тест	7
2.4 Данные предсказуемости для русского языка	8
3. Обзор литературы	9
3.1 Языковые модели и поведение при чтении	9
3.2 Прямые сравнения предсказаний моделей и людей	10
3.3 Исследования для русского языка	11
4. Предыдущее исследование	13
4.1 Данные и постановка задачи	13
4.2 Методология разметки	14
4.3 Ключевые результаты	14
4.4 Ограничения предыдущего подхода	15
5. Новая методология	16
5.1 Данные	16
5.2 Получение распределений от GPT-4o-mini	17
5.3 Получение распределений от Llama	18
5.4 Метрики попадания на уровне целевого слова	19
5.5 Метрики лексического уровня	19
5.6 Метрики синтаксического уровня	21
5.6.1 Инструменты разметки частей речи	21
5.6.2 Ранжированное пересечение POS@k	22
5.6.3 Корреляция POS-распределений	22
5.6.4 Анализ морфологических признаков	22
5.7 Метрики семантического уровня	23
5.7.1 Метрика сравнения Centroid Similarity	23
5.7.2 Семантическое перекрытие распределений: Precision, Recall и F1	24
5.8 Способы анализа контекста	25
5.8.1 Энтропия контекста	25
5.8.2 Морфологические ограничения контекста	26
6. Результаты	26
6.1 Результаты на уровне целевых слов	26
6.1.1 Попадание в целевое слово; GPT-4o-mini	26
6.1.2 Попадание в целевое слово; Llama	27
6.2 Результаты лексических метрик	28
6.3 Результаты синтаксических метрик	29

6.3.1 Результаты для POS_intersection@k	29
6.3.2 Результаты корреляционного анализа POS-распределений	30
6.3.3 Результаты кросс-корреляционного анализа POS-тегов	32
6.3.4 Результат корреляционного анализа на уровне морфологических признаков	37
6.3.5 Обобщенные выводы синтаксических метрик	40
6.4 Результаты семантических метрик	41
6.4.1 Результат метрики Centroid Similarity	41
6.4.2 Результат метрик Precision, Recall и F1	41
6.5 Результаты анализа контекста	43
6.5.1 Результат влияния энтропии контекста	43
6.5.1 Результат анализа предсказуемости морфологических параметров целевого слова	45
7. Выводы	45
Библиография	47
Приложения	48
Приложение 1. Результаты курсовой работы второго курса	48
Приложение 2. Код beam search для GPT	51
Приложение 3. Код beam search для Llama	52

1. Введение

Одной из фундаментальных особенностей человеческой обработки языка является способность предсказывать последующие слова на основе контекста. В исследованиях чтения степень этого прогнозирования операционализируется через понятие **предсказуемости** (predictability) слова в контексте.

В психолингвистических экспериментах предсказуемость слов принято оценивать при помощи cloze-теста: участникам эксперимента предлагается незаконченное предложение и ставится задача продолжить его одним словом, которое должно следовать далее. Однако сбор норм предсказуемости, как и любых других экспериментальных норм, требует значительных временных и финансовых затрат исследователей. В связи с этим за последние годы появился ряд исследований, в которых ставится большой исследовательский и методологический вопрос: могут ли большие языковые модели (LLM) заменить людей при сборе психолингвистических норм, и в частности норм предсказуемости?

Однозначного ответа на данный вопрос пока не существует, однако в литературе представлены аргументы как в поддержку, так и против замены реальных испытуемых большими языковыми моделями. С одной стороны, некоторые авторегрессионные модели на основе архитектуры Transformer в процессе обучения оптимизируются для предсказания следующего токена по предшествующему левому контексту. На этапе генерации текста такие модели последовательно выбирают следующий токен, максимизируя условную вероятность этого токена. Поэтому процесс генерации в определенной мере схож с процессом чтения, при котором люди также на каждом шаге выбирают наиболее вероятное продолжение. С другой стороны, совпадение наиболее вероятного предсказания модели с ответом человека или с контекстуально ожидаемым словом еще не свидетельствует о сопоставимости процессов: модель может верно угадывать какие-то слова, так как они являются наиболее вероятными, потому что часто встречались при обучении, однако распределять вероятностную массу других генераций иначе, чем это делает человек. Таким образом, центральный методологический вопрос заключается не в точности попадания, а в степени соответствия распределений предсказаний на различных языковых уровнях.

Цель настоящего исследования — оценить степень соответствия вероятностных распределений, генерируемых большими языковыми моделями (LLM), распределениям предсказаний человека при обработке текста в парадигме **cloze-теста**.

В отличие от работы, выполненной в прошлом году, где сравнение проводилось на уровне отдельных ответов с использованием ручной разметки, в настоящем исследовании предлагается принципиально иной методологический подход: сравниваются не отдельные предсказания, а полные вероятностные распределения, что позволяет ответить не на вопрос «угадала ли модель то же слово, что и человек», а на более фундаментальный вопрос — «насколько распределение вероятностной массы в LLM соответствует человеческому?»

В рамках данной работы была разработана и применена новая методология сравнения вероятностных распределений предсказаний больших языковых моделей и людей в парадигме cloze-теста на материале русского языка. Центральным методологическим решением стал модифицированный алгоритм beam search для двух моделей — GPT-4o-mini и Llama 3.1. Сравнение предсказаний проводилось на лексическом, морфосинтаксическом и семантическом уровнях. Полученные результаты показывают, что GPT-4o-mini демонстрирует достаточно высокую согласованность с человеческими данными по ряду морфологических категорий и характеризуется высокой корреляцией с вероятностями целевого слова; вместе с тем ни одна из рассмотренных моделей не способна в полной мере воспроизвести лексическое и семантическое разнообразие человеческих предсказаний. Данные, код для извлечения предсказаний, код для анализа, а также результаты обработки данных можно найти на [github](https://github.com/VeraMonina/KR3)¹.

2. Предсказуемость в психолингвистике

2.1 Статические и динамические факторы обработки слова

Процесс обработки текста при чтении происходит инкрементально: каждое новое слово интегрируется в синтактико-семантическое представление, составленное на основе результатов обработки предыдущего контекста (Lyu et al., 2024). Одним из способов эмпирического изучения того, как люди обрабатывают слова при чтении, в каких контекстах эта обработка облегчается является регистрация движений глаз (eye-tracking).

Принято разграничивать статические и динамические параметры, которые влияют на сложность обработки слов. Статические переменные — длина слова в символах и его абсолютная лексическая частотность — остаются неизменными вне зависимости от контекста. Динамическая переменная — предсказуемость — определяется контекстом и может изменяться в зависимости от него. Предсказуемость определяется, как вероятность угадывания целевого слова, на основе предшествующего материала. Исследования, проведенные на разных языках, показывают, что чем слово предсказуемее, короче и

¹ <https://github.com/VeraMonina/KR3>

частотнее, тем с меньшим временем фиксации оно ассоциировано и тем с большей вероятностью оно будет пропускаться при чтении (Ashby et al., 2005; Ehrlich & Rayner, 1981; Rayner, 1998).

Важно, что предсказуемость и частотность, хотя и коррелируют, но отражают разные источники информации. Частотность характеризует общее лексическое распространение слова в языке, тогда как предсказуемость — контекстно-специфические ожидания читателя. Одно и то же слово может предсказываться с разной вероятностью в зависимости от контекста, но его абсолютная частотность не будет меняться.

2.2 Теория surprisal

Формальное описание связи между предсказуемостью и когнитивной нагрузкой дает теория **surprisal** (Hale, 2001; Levy, 2008). Согласно данной теории, трудность обработки слова x в контексте c пропорциональна его обратному информационному содержанию и выражается как отрицательный двоичный логарифм условной вероятности этого слова в данном контексте:

$$Surprisal(x) = \log_2(1 / P(x | c)) = -\log_2 P(x | c)$$

Менее предсказуемые слова имеют более высокий surprisal и требуют больших когнитивных ресурсов для обработки. Surprisal хорошо предсказывает как данные айтрекинга, так и нейрофизиологические реакции — в частности, амплитуду компонента N400 в ЭРП-исследованиях (Frank et al., 2013).

Теория surprisal устанавливает связь между психолингвистикой и применением языковых моделей: если модель приписывает слову вероятность P , то величина, обратная этой вероятности, может служить мерой когнитивной нагрузки, ожидаемой у человека при обработке данного слова.

2.3 Cloze-тест

Эмпирически предсказуемость измеряется при помощи **cloze-теста** (Taylor, 1953): испытуемым предъявляется незавершенное предложение (см. примеры 1 и 2), и их задача заключается в том, что им надо назвать одно слово, которое, по их мнению, с наибольшей вероятностью следует далее. Доля участников, назвавших слово x , служит оценкой его cloze-вероятности. В рамках данной экспериментальной парадигмы различают следующие понятия: предсказание — любая лексическая единица, продуцируемая респондентом; целевое слово — единица, фактически присутствовавшая в исходном (полном) предложении на месте пропуска; левый контекст — фрагмент предложения, доступный испытуемому до момента генерации ответа; правый контекст — завершающая часть

полного предложения, следующая за целевым словом и не предъявляемая испытуемому в теста.

(1) В лесу ветром _____

(2) Причиной аварии был мобильный _____

В большинстве исследований ответы оцениваются бинарно (1 в случае совпадения ответа с целевым словом, 0 — в противном случае), хотя такой подход игнорирует семантически и грамматически приемлемые альтернативы. Важно отметить, что в рамках данного эксперимента не принято говорить о «правильных» или «неправильных» предсказаниях, и **интерпретация результатов в терминах «ошибка / не ошибка» некорректна**. Предсказания с нулевой вероятностью не являются ошибочными; они сигнализируют о том, что для обработки данного целевого слова потребуется затратить больше когнитивных ресурсов, что, вероятно, проявится в виде регрессивных саккад к началу слова или даже к началу всего предложения.

В рамках настоящего исследования не анализируются ситуации оценки предсказуемости, в которых испытуемым предъявляется полный контекст (как левый, так и правый) и предлагается восстановить пропущенное слово. Данное ограничение накладывает определенные рамки как на выбор модели для исследования, так и на последующую методологию получения предсказаний.

2.4 Данные предсказуемости для русского языка

Русскоязычные исследования подтверждают общие кросс-лингвистические закономерности влияния предсказуемости на чтение.

В работе (Laurinavichyute et al., 2019) описывается создание Russian Sentence Corpus² — корпуса, в котором хранятся данные о движении глаз при чтении стандартных носителей русского языка. Для создания корпуса были собраны как айтрекинговые нормы, так и нормы предсказуемости. На основе собранных данных авторы показали, что высокая предсказуемость значительно снижает длительность первой и суммарной фиксации, уменьшает вероятность регрессий и в совокупности с длиной слова и его частотностью влияет на вероятность его пропуска при чтении.

² <https://www.hse.ru/en/neuroling/research/RSC>

3. Обзор литературы

3.1 Языковые модели и поведение при чтении

Уже в ранних исследованиях было установлено, что качество предсказания следующего слова языковой моделью коррелирует с поведением человека при чтении. В частности, в классической работе (Smith & Levy, 2013) были использованы вероятностные оценки слов, полученные на основе статистических *n*-gram моделей, и было показано, что время чтения слова логарифмически связано с его предсказуемостью в контексте. Авторы сравнивали вероятности слов с данными чтения с самостоятельным регулированием скорости (*self-paced reading task*) и айтрекингowych данных и обнаружили, что менее вероятные слова вызывают увеличение времени обработки. Полученные результаты подтвердили, что *surprisal*, вычисляемый языковыми моделями, может служить надежным предиктором когнитивной нагрузки при чтении.

Данное исследование стало одним из ключевых аргументов в пользу использования вероятностных языковых моделей в психолингвистических заданиях, поскольку оно продемонстрировало, что оценки вероятности, генерируемые моделью, отражают закономерности человеческой обработки языка. В дальнейшем этот подход был распространен сначала на нейросетевые рекуррентные модели (RNN), а затем и на трансформерные архитектуры (Transformers).

В частности, в работах (Wilcox et al., 2020), а также (Merx & Frank, 2020) продемонстрировали, что чем точнее нейросетевая модель предсказывает последующий токен, тем в большей степени ее *surprisal* объясняет вариативность времени чтения. Также было показано, что при сравнении различных архитектур (от *n*-gram до LSTM и Transformer) наилучшее соответствие психолингвистическим данным неизменно демонстрируют наиболее новые модели семейства Transformer.

В работе (Wilcox et al., 2023) результаты предыдущего исследования были распространены на 11 языков, относящихся к пяти языковым семьям (изначально исследование проводилось на материале английского языка), с использованием мультязычной трансформерной модели mGPT и ряда молилингвальных моделей. Для сопоставления данных между языками авторы использовали корпус MECO, содержащий айтрекингowe данные чтения параллельных текстов. В рамках исследования проверялись три ключевые гипотезы: связь *surprisal* со временем чтения, влияние контекстной энтропии на обработку текста, а также линейность зависимости между *surprisal* и временем чтения. Авторы показали, что как *surprisal*, так и показатели контекстной энтропии позволяют значительно повысить точность предсказания времени чтения по сравнению с базовыми моделями, причём соответствующие эффекты наблюдаются для всех рассматриваемых языков. Полученные результаты подтверждают, что большие

языковые модели способны приближенно моделировать вероятностные ожидания человека в процессе чтения, по крайней мере на лексическом уровне и при наличии достаточного объема репрезентативных обучающих данных.

В работе (Oh & Schuler, 2023) на английском материале показали, что объем обучающих данных нелинейно влияет на качество аппроксимации: модели, обученные на 2 млрд токенов и более, лучше соответствуют человеческим данным, однако при очень больших объемах (свыше 300 млрд токенов) это соответствие вновь снижается. Таким образом, «средняя» по масштабу LLM может быть наиболее подходящей моделью, отражающей человеческие ожидания при чтении.

Lopes Rego, Snell & Meeter (2024) показали, что на английском материале оценки предсказуемости, полученные из LLM (GPT-2, LLaMA), превосходят традиционные cloze-вероятности при объяснении айтрекингowych норм в модели чтения OB1-reader³. Авторы интерпретируют это как свидетельство того, что LLM-surprisal в ряде контекстов лучше описывает когнитивную стоимость обработки, чем человеческие нормы.

3.2 Прямые сравнения предсказаний моделей и людей

В последние годы в исследованиях смещается фокус с вопроса «объясняют ли модели время чтения?» на вопрос «совпадают ли предсказания модели с ответами людей в cloze-тесте?». При этом в существующих работах наблюдается разнообразие методологий извлечения ответов из моделей, ответы сравниваются по разным метрикам, набор изученных языков остается ограниченным, что в совокупности затрудняет прямое сопоставление результатов между исследованиями. Ниже рассматриваются работы, в которых авторы предприняли систематический анализ расхождений между человеческими и модельными предсказаниями в cloze-тесте.

Jacobs, Grobol & Tsang (2024) провели масштабный сравнительный анализ данных cloze-теста и генераций LLM на материале английского языка. Авторы показали, что предсказания моделей систематически расходятся с человеческими как на лексическом, так и на семантическом уровне. В частности, модели недооценивают вероятности наиболее частотных человеческих ответов и переоценивают редкие ответы, тем самым демонстрируя совершенно другое ранжирование предсказаний по вероятности. Кроме того, анализ пространств семантических эмбеддингов выявил лишь частичное пересечение между семантическими полями предсказаний. В результате авторы делают выводы, что большие языковые модели не могут служить прямой заменой при сборе норм предсказуемости.

³OB1-reader — вычислительная когнитивная модель чтения, описывающая процессы зрительного распознавания слов при чтении. Модель предполагает параллельной обработки орфографической информации и описывает, каким образом читатель одновременно извлекает информацию из нескольких слов в пределах зрительного поля, что позволяет моделировать динамику фиксаций и временные характеристики чтения.

В свою очередь, в работе (Iliia & Aziz, 2024) было проведено сравнение распределений вероятностей человека и нескольких LLM на материале корпуса Provo (корпус содержит данные о движении глаз 84 взрослых носителей английского языка). Полученные данные показывают, что люди распределяют вероятность по широкому спектру лексем, в то время как модели более сконцентрированы на отдельных словах. Такое поведение людей авторы называют *human uncertainty*.

Nentcheva, Schuster & Santi (2025) показали, что при обработке сложных синтаксических конструкций, в частности относительных предложений, модельные оценки *surprisal* (извлеченные из GPT-2) расходятся с человеческими предпочтениями. В их эксперименте с нелокальными зависимостями человеческое предпочтение *subject-gap* (0.91) значительно превышало предсказанное моделью (0.65), что ставит под сомнение применимость LLM для исследований сложной синтаксической обработки, особенно в условиях повышенных когнитивных нагрузок на память.

3.3 Исследования для русского языка

Несмотря на устойчивый рост числа исследований, посвященных сопоставлению человеческих предсказаний и предсказаний языковых моделей в задаче *cloze-теста*, для русского языка данное направление остается сравнительно малоизученным. Между тем русский язык представляет особый интерес для исследования предсказуемости из-за своей развитой морфологической системы. В отличие от английского языка, где грамматические характеристики выражены относительно не настолько разнообразно, русский позволяет анализировать не только предсказание конкретной лексемы, но и вероятностные ожидания относительно ее морфосинтаксических свойств — части речи, падежа, числа, рода, времени и других грамматических категорий.

Одной из первых работ, непосредственно рассматривающих применение языковых моделей к задаче генерации ответов в *cloze-тесте* на русском языке, является исследование (Nikiforova et al., 2020). Авторы сравнивали несколько типов языковых моделей, включая статистические *n-gram* модели и нейросетевые рекуррентные модели типа LSTM. В качестве материала использовались *close-нормы* из Russian Sentence Corpus, на основе которых оценивалось совпадение предсказаний людей и моделей. Результаты показали, что нейросетевые модели существенно превосходят статистические модели по качеству генерации и способны производить грамматически корректные и семантически приемлемые ответы. При этом совпадение с человеческими предсказаниями оставалось ограниченным, особенно в контекстах с высокой степенью неопределенности и большим количеством допустимых продолжений. Эти результаты подтверждают результаты, полученные на английском языке в других исследованиях.

Авторы также отмечают, что морфологическая сложность русского языка существенно усложняет задачу языкового моделирования: модель должна предсказывать не только лексему как таковую, но и ее корректную морфологическую реализацию в конкретном синтаксическом окружении. В частности, ошибки моделей нередко были связаны не с выбором семантически неподходящего продолжения, а с нарушением морфологического согласования или использованием неверной словоформы. При этом анализ в работе был сосредоточен преимущественно на top-k продолжениях и точечных предсказаниях моделей, тогда как структура вероятностного распределения ответов практически не рассматривалась.

Важной для настоящего исследования является работа (Lopukhina et al., 2021), посвященная сопоставлению cloze-вероятностей людей и вероятностей, полученных из корпусных языковых моделей, на материале русского языка. Авторы также использовали Russian Sentence Corpus и дополнительно дособрали cloze-нормы от 605 носителей русского языка. В качестве моделей сравнивались статистические 5-gram модели и рекуррентные нейросетевые модели типа LSTM, обученные на крупных русскоязычных корпусах, включая Национальный корпус русского языка (НКРЯ)⁴ и Taiga corpus⁵. По результатам предварительного сравнения именно LSTM-модель продемонстрировала наилучшее качество языкового моделирования и была использована в основном анализе.

Ключевой особенностью работы является переход от анализа исключительно на лексическом уровне к анализу вероятностей морфосинтаксических признаков. Авторы сравнивали не только вероятность конкретного целевого слова, но и распределения грамматических характеристик продолжения, включая часть речи, падеж, число, род и временные характеристики глагольных форм. Было показано, что совпадение между человеческими и модельными вероятностями существенно зависит от уровня анализа.

На лексическом уровне, как и в других исследованиях, что корреляция между вероятностными распределениями ограничена. Авторы связывают это с различиями в структуре распределений: языковые модели распределяют вероятность между большим числом семантически близких альтернатив, тогда как ответы людей сконцентрированы на ограниченном наборе лексем (что в частотности увеличивает их абсолютную вероятность). Также, в исследовании был проведен анализ на морфосинтаксическом уровне, который показал, что и люди, и модель демонстрировали схожие ожидания относительно грамматических характеристик будущего слова. Особенно высокие показатели совпадения были выявлены для предсказания частей речи и падежей существительных. В результате, исследование показало, что языковые модели значительно лучше аппроксимируют человеческие ожидания на уровне грамматической структуры продолжения, чем на уровне конкретных лексических реализаций.

⁴ <https://ruscorpora.ru/>

⁵ https://tatianashavrina.github.io/taiga_site/

Результаты указанных исследований имеют большое значение для настоящего исследования. Во-первых, они подтверждают необходимость анализа предсказаний не только на уровне совпадения лексем, но и на других языковых уровнях, и показывают, что сопоставление человека и модели не может ограничиваться исключительно проверкой совпадения попадания в конкретное целевое слово (как принято в cloze-тесте). Во-вторых, результаты этих исследований демонстрируют необходимость анализа вероятностных распределений как таковых, поскольку совпадение наиболее вероятного продолжения ещё не означает совпадения структуры неопределённости у человека и языковой модели. Более того, ряд работ показывает, что даже при частичном совпадении набора предсказываемых лексем порядок их вероятностного ранжирования может существенно различаться.

4. Предыдущее исследование

В предыдущей курсовой работе на материале Russian Sentence Corpus было проведено сравнение предсказаний нескольких языковых моделей и людей. Описание этого исследования важно по двум причинам: во-первых, оно создает контекст для новой методологии; во-вторых, выявленные ограничения прямо мотивируют изменение подхода, представленного в данной курсовой работе. Результаты, текст курсовой работы и код можно найти на гитхабе⁶.

4.1 Данные и постановка задачи

Материал исследования — 144 адаптированных предложения из НКРЯ, которые были сбалансированы по длине, а также дополнительно облегчены, и данные cloze-теста от людей (Laurinavichyute et al., 2019).

Для каждого предложения имелся левый контекст, целевое слово и правый контекст. Все 144 предложения содержат по одному целевому слову (которые взять из StimulStat (Alexeeva et al., (2018)), не расположенному ни в абсолютном начале, ни в абсолютном конце предложения. Целевые слова сбалансированы по длине (короткие 3-4 знака / средние 5-7 / длинные 8-10), частотности (высокая / низкая) и части речи (существительные / глаголы / прилагательные). Важно отметить, что по частям речи были сбалансированы по схеме 72 x 36 x 36, где больше всего было существительных. Такой дисбаланс связан с тем, что в русском языке очень мало коротких (3-4 знака) прилагательных и глаголов. После фильтрации несуществующих словоформ финальный выборка включает в себя 6 705 предсказаний; для каждого контекста от 1 до 63 уникальных ответов.

В эксперименте прошлого года от каждой модели получали от 1 до 3 предсказаний путем изменения параметров генерации (top_k, top_p, temperature, применение beam search

⁶ https://github.com/VeraMonina/kursovaya_2025

с высокими ограничениями вероятности каждого продолжение). Исследовались три модели: ruGPT-3.5 (13 млрд параметров) и Llama-3.1 (8 млрд) локально, Qwen/QwQ (32,5 млрд) в zero-shot режиме. Дополнительно в отдельном эксперименте исследовались RuModernBERT-small и RuModernBERT-base — модели с двунаправленной архитектурой, для которых подавались как левый, так и правый контексты. То есть было проведено два независимых эксперимента: первый, который полностью повторяет методику проведения cloze-теста, и второй, который сводит задачу предсказания к задаче угадывания целевого слова, так как в модель подавался весь контекст, с вырезанным одним словом. Графики со сводными результатами данного исследования можно посмотреть в приложении 1.

4.2 Методология разметки

Принципиальным решением предыдущей работы была разработка детальной системы разметки, позволяющей выйти за рамки бинарной оценки «совпадения / не совпадения» с целевым словом. Каждое предсказание размечалось вручную по двум независимым шкалам с учетом как левого контекста, так и правого (то есть каждое предсказание интегрировалось в изначальное предложение, заменяя целевое слово).

Семантическая разметка включала в себя шесть тегов: Exact (точное совпадение со стимулом), Close (тот же корень, но другая форма), Accept (семантически приемлемое слово), Lex (верная часть речи, но неприемлемое слово), POS_Error (неверная часть речи), Error (несуществующее слово). Грамматическая разметка фиксировала морфосинтаксические ошибки: Gov (ошибка в управлении), Gender, Num, AgrGender, AgrNum, AgrCase, Brev, Asp, Tense, Syntax и ряд других.

Такая разметка позволила учитывать частично корректные ответы и разграничивать семантические и грамматические источники ошибок — то, что невозможно оценить при бинарной оценке.

4.3 Ключевые результаты

Количественные результаты показали, что модели демонстрируют более высокие количественные показатели: доля семантически приемлемых предсказаний у моделей выше. Это объясняется принципиальным различием в стратегии: модели выбирают частотные, синтаксически простые варианты, тогда как люди тяготеют к комплексным синтаксическим конструкциям (прилагательное + существительное, предлог + существительное), которые в рамках ответа одним словом и интеграции его в изначальный контекст автоматически получают низкие оценки.

На уровне частей речи целевого слова было обнаружено, что существительные предсказываются лучше всего (как людьми, так и моделями), а прилагательные — хуже всего. При верно угаданной части речи люди допускают меньше грамматических ошибок,

чем модели: для существительных разница между долей верных попаданий в POS и долей грамматически корректных предсказаний у людей составляет $\approx 3\%$, у моделей — $\approx 11\%$.

Также было замечено, что модели чаще ошибаются в выборе падежа (ошибки Gov), когда вершина конструкции содержится в левом видимом контексте. Люди, напротив, делают больше ошибок в выборе части речи (POS_Error), что отражает их склонность к синтаксически сложным конструкциям, которые состоят из более чем одного слова.

Модели BERT, имеющие доступ ко всему контексту, показали интересные результаты: более 70% семантически приемлемых и 86% грамматически верных предсказаний, а также гораздо больше попаданий в целевое слово, как по сравнению с людьми, так и по сравнению с моделями. Это подтверждает, что доступ к правому контексту кардинально облегчает задачу.

Помимо этого было проанализировано влияние длины и частотности целевого слова на то, как легко оно будет предсказываться. Было показано, что ни один из этих параметров не демонстрирует статистически значимой линейной связи с общей семантической приемлемостью предсказаний как у людей, так и у языковых моделей. Вместе с тем длина и частотность оказывают существенное влияние на вероятность точного предсказания целевого слова. И люди, и языковые модели значительно чаще воспроизводят целевую лексику в случаях, если она короткая и высокочастотная. Для длинных и низкочастотных слов, напротив, возрастает доля семантически близких предсказаний. Данный эффект особенно ярко выражен в ответах людей: участники демонстрируют более высокую чувствительность к длине и частотности слова, чем языковые модели, чаще переходя от точного воспроизведения к генерации семантически приемлемых альтернатив.

4.4 Ограничения предыдущего подхода

Несмотря на детальность разметки, предыдущий подход имеет принципиальное ограничение, напрямую влияющее на интерпретацию результатов.

Разметка — в частности, грамматическая — по существу оценивала предсказание с учетом полного предложения, включая правый контекст. Так, тег Num (ошибка в числе) или Tense (ошибка во времени глагола) могли ставиться на основании того, что предсказание не согласуется с тем, что стоит после. Но ни люди, ни языковые модели в эксперименте правого контекста не видели: они предсказывали слово, опираясь исключительно на левый контекст.

Это создает методологическую ошибку: предсказание оценивается по критерию, который недоступен «испытуемому» в момент ответа. Предсказание, идеально обоснованное левым контекстом, получает штраф за несовпадение с тем, что было в

исходном контексте после целевого слова. Грамматические теги, выставленные таким образом, измеряют не то, насколько хорошо испытуемый решил свою задачу, а то, насколько его ответ вписывается в уже существующее предложение — что принципиально разные вещи.

Данный изъян в меньшей степени затрагивает семантическую разметку (Асcerpt, Lex и т.д.), поскольку она в основном опирается на левый контекст. Однако и здесь возможны случаи, когда правый контекст влиял на решение об корректности предсказания.

Более фундаментальное ограничение состоит в самом объекте анализа. Предыдущее исследование сравнивало точечные предсказания — от 1 до 3 ответов от каждой модели. Это принципиально иная задача, чем сравнение распределений вероятностей: точечное предсказание говорит лишь о «лучшей точке» модели, но ничего — о том, как она распределяет неопределенность. В то время, как у людей есть контексты, в которых они могут быть склонны к одному варианту предсказания, но в большинстве контекстов вариативность присутствует, как на лексическом уровне, так и на синтаксическом. Именно это ограничение и мотивирует переход к новой методологии.

Следует, однако, отметить, что даже при использовании указанной методологии сохраняются систематические различия в характере предсказаний между языковыми моделями и людьми, что является ключевым результатом исследования прошлого года.

5. Новая методология

5.1 Данные

Как уже было сказано ранее, новые нормы предсказуемости для людей не вычислялись заново, а были взяты из Russian Sentence Corpus. Целевые слова были автоматически размечены, а затем вручную проверены авторами статьи. Для сопоставимости с предсказаниями все параметры были приведены к формату, совместимому с разметкой библиотеки Stanza.

Все предсказания (как людей, так и моделей) были автоматически размечены по единой схеме. На первом этапе автоматическая разметка текста выполнялась с использованием нейросетевой библиотеки Stanza⁷, основанной на схеме Universal POS Tags (UPOS). Для каждого предсказания были выделены:

- лемма;
- морфологические признаки;
- совпадение с целевым словом на поверхностном уровне (бинарная метрика);
- совпадение на уровне лемм (бинарная метрика);

⁷ <https://github.com/stanfordnlp/stanza>

- совпадение на уровне части речи (бинарная метрика);
- список совпавших морфологических признаков.

На втором этапе для уточнения частеречной разметки был использован анализатор PyMorphy3⁸ (схема тегов OpenCorpora), который обеспечивает более детальную классификацию частей речи для русского языка. Кроме того, с использованием морфологического анализатора PyMorphy3 для каждого слова определялся признак *is_russian*, отражающий наличие слова в словарной базе анализатора. Это позволило отфильтровать предсказания как людей, так и модели, исключив из анализа ответы с орфографическими ошибками или случайные наборы символов.

5.2 Получение распределений от GPT-4o-mini

В настоящем исследовании используется мультязычная модель GPT-4o-mini⁹ — компактный вариант семейства GPT-4o, оптимизированный по скорости и стоимости при сохранении высоких языковых способностей. Модель использовалась в zero-shot режиме через API.

Ключевым методологическим решением является использование модифицированного алгоритма beam search для извлечения полного вероятностного распределения предсказаний для каждого контекста. В отличие от стандартного beam search, отсекающего гипотезы по вероятности (score), предложенная процедура итеративно расширяет все top-k кандидатов на каждом шаге — то есть получается поиск в ширину без отсечения по вероятности (см. приложение 2). Алгоритм стартует из левого контекста и итеративно расширяет все ветви, накапливая логарифмы вероятностей. Луч завершается, если:

- генерируется любой токен после первого, содержащий границу слова (пробел, знак пунктуации, перевод строки и т.д);
- глубина ветки достигает восьми токенов (в рамках предварительных экспериментов было выявлено, что для данной модели достаточно 2-5 токенов для генерации полноценного слова, но мы сделали чуть более лояльные ограничения, чтобы точно не потерять какие-либо предсказания). Итоговая вероятность каждого кандидата считалась по такой формуле:

$$P = \exp(\sum \log\text{-prob по всем токенам пути})$$

После дедупликации по нормализованной поверхностной форме и применения отчистки по параметру *is_russian* для каждого контекста получилось извлечь от 2 до 1 067

⁸ <https://pypi.org/project/pymorph3/>

⁹ <https://developers.openai.com/api/docs/models/gpt-4o-mini>

уникальных словоформ-кандидатов. Этот подход впервые делает корректным сравнение именно распределений (а не точечных предсказаний): вся вероятностная масса модели в пределах видимых ветвей сохранена и доступна для анализа.

5.3 Получение распределений от Llama

В качестве второй языковой модели в исследовании использовалась Llama 3.1 (которая была уже использована в исследовании прошлого года) — открытая авторегрессионная модель, развёрнутая локально. Выбор данной модели был обусловлен несколькими факторами. Во-первых, использование локальной модели обеспечивает полную воспроизводимость процедуры генерации и независимость от изменений внешнего API. Во-вторых, по сравнению с GPT-4o-mini (далее просто GPT) модель Llama обладает существенно меньшим масштабом и вычислительной сложностью, что позволяет проверить, насколько наблюдаемые эффекты определяются размером модели и сложностью архитектуры.

Извлечение распределений осуществлялось при помощи модифицированного алгоритма beam search, аналогичного использованному для GPT. Вероятность каждого кандидата вычислялась как произведение условных вероятностей токенов на соответствующем пути, то есть как совместная вероятность всех токенов, входящих в сгенерированную словоформу.

В отличие от GPT, генерация для Llama была ограничена подмножеством токенов, соответствующих кириллическим продолжениям. Такое ограничение вводилось с целью повышения вычислительной эффективности поиска и исключения нерелевантных продолжений на других языках. Вследствие этого полученные значения отражают не абсолютные вероятности слов во всём словаре модели, а относительные вероятности внутри пространства допустимых русскоязычных кандидатов.

После завершения поиска выполнялись дедупликация по нормализованной поверхностной форме и фильтрация по признаку *is_russian*. Дополнительно вероятности Llama нормализовались внутри каждого контекста: суммарная вероятность всех предсказаний в пределах одного контекста приводилась к 1. Такая нормализация позволяет использовать модельные распределения для сопоставления рангов и структуры top-k предсказаний с данными GPT и результатами cloze-теста людей, не интерпретируя при этом абсолютные значения вероятностей как непосредственно сопоставимые между моделями. В результате на каждый контекст приходится от 107 до 577 уникальных предсказаний.

5.4 Метрики попадания на уровне целевого слова

Попадание в целевое слово остаётся одной из ключевых метрик в психолингвистических исследованиях предсказуемости, поскольку именно она лежит в основе классической cloze-процедуры. В настоящем исследовании для каждого контекста вычислялась вероятность, которую каждый источник присваивает целевому слову.

Для человеческих ответов вероятность целевого слова p_{human} определялась как суммарная доля ответов, лемма которых совпадала с леммой целевого слова, в пределах данного контекста. Для моделей вероятность целевого слова p_{model} вычислялась как сумма вероятностей всех предсказаний, совпадающих с леммой целевого слова.

На основе этих вероятностей для каждого контекста определялась принадлежность этого контекста к одному из четырёх классов:

- $C1$: целевое слово предсказано и людьми, и моделью;
- $C2$: предсказано только людьми;
- $C3$: предсказано только моделью;
- $C4$: не предсказано ни теми, ни другими.

Поскольку классификация зависит от конкретной модели, один и тот же контекст может относиться к разным классам для GPT и Llama, поэтому результаты двух моделей рассматриваются раздельно.

Для оценки степени согласованности между человеческими и модельными вероятностями целевого слова по всем 144 контекстам вычислялись коэффициенты корреляции Пирсона и Спирмена.

Помимо корреляционного анализа вероятностей целевого слова, отдельно оценивалась точность воспроизведения его частеречных и морфологических характеристик. Для каждого контекста вычислялась доля предсказаний, совпадающих с целевым словом по части речи, а также по отдельным морфологическим признакам — числу, падежу, времени глаголов и других.

5.5 Метрики лексического уровня

Сравнение на лексическом уровне основано на сопоставлении множеств человеческих ответов и модельных предсказаний для каждого контекста. Важно, что здесь сравниваются не вероятности отдельных предсказаний, а сами множества лексем, и ставится такой вопрос: какая доля предсказаний людей перекрывается топ-k предсказаниями модели. Для этого относительно каждого контекста формировались 2 множества:

- L_{human} — множество уникальных человеческих ответов;

- $L_model@k$ — множество top-k предсказаний модели, отсортированных по убыванию вероятности.

Сравнение проводилось в двух вариантах:

- на уровне поверхностных форм;
- на уровне лемматизированных форм.

Лемматизированный вариант необходим для проверки того, влияет ли приведение слов к словарной форме на увеличение доли покрытия человеческих предсказаний. Сопоставление множеств, составленных на основе поверхностных словоформ и лемматизированных предсказаниях, позволяет оценить вклад морфологической вариативности. Если доля перекрытий по леммам существенно превышает аналогичный показатель для поверхностных форм, это свидетельствует о том, что расхождения между предсказаниями модели и людей обусловлены не выбором разных лексем, а особенностями генерации: из-за используемого алгоритма поиска модель может «уходить» в лучи beam search, обладающие высокой вероятностью первых токенов, и порождать большое количество словоформ, относящихся к одним и тем же леммам, но различающихся морфологически.

На основе этих множеств рассчитывалась метрика перекрытия $overlap@k$:

$$overlap@k = |L_human \cap L_model@k| / |L_human|$$

Метрика показывает долю уникальных человеческих ответов, присутствующих среди top-k предсказаний модели. Значение 0 говорит о том, что ни одно предсказание людей не попало в множество предсказаний модели, а значение 1 говорит о полном пересечении множеств. Анализ проводился для $k \in \{5, 10, 15, 20, 50, 100, 200, 400\}$.

Динамика насыщения метрики $overlap@k$ при увеличении k отражает структурные особенности вероятностного распределения модели. Если значение $overlap@k$ быстро выходит на плато (т.е. достигает максимума уже при малых k), означает, что предсказания, совпадающие с человеческими ответами, сосредоточены среди наиболее вероятных предсказаний модели. Добавление менее вероятных предсказаний не приводит к покрытию новых человеческих ответов. Либо, если $overlap@k$ продолжает монотонно расти во всём диапазоне k , это свидетельствует о более размытом распределении: человеческие ответы распределены по всему распределению модели, и для их покрытия необходимо учитывать значительное число низковероятных предсказаний.

5.6 Метрики синтаксического уровня

Главный вопрос на синтаксическом уровне состоит в следующем: в какой мере люди и языковая модель согласованы в своих ожиданиях относительно грамматических свойств следующего слова. При этом под согласованностью понимается не совпадение с конкретным целевым словом, а сходство вероятностных распределений: если люди в контексте c ожидают слово x определенной части речи и в определенной форме, ожидают ли модели то же самое.

Для ответа на этот вопрос предсказания людей и модели размечались по частям речи, и для каждого контекста строились два взвешенных по вероятности распределения. Например, если в некотором контексте люди предсказывали существительные с суммарной вероятностью 0.70, глаголы — с 0.20 и прилагательные — с 0.10, то распределение людей по частям речи для этого контекста имеет вид {NOUN: 0.70, VERB: 0.20, ADJ: 0.10}. Аналогичное распределение строилось для модели. Такой подход позволяет сравнивать не отдельные предсказания, а полные распределения грамматических ожиданий.

5.6.1 Инструменты разметки частей речи

Как уже было частично описано в разделе 5.1 разметка проводилась двумя инструментами, применявшимися независимо друг от друга. Основной анализ строился на разметке stanza — нейросетевого морфосинтаксического анализатора, работающий на основе Universal POS Tags (UPOS). Схема UPOS насчитывает 17 тегов и обеспечивает единообразную разметку для всех языков; для русского языка из них наиболее релевантны открытые классы (NOUN, VERB, ADJ, ADV) и функциональные классы (ADP, CCONJ, SCONJ, PART, NUM, DET, PRON).

Для уточнения результатов дополнительно применялся анализатор PyMorphu3 (схема тегов OpenCorpora). Необходимость второго инструмента обусловлена тем, что в stanza в одну категорию VERB объединяются финитные глаголы, инфинитивы, причастия и деепричастия. Между тем эти формы занимают принципиально разные синтаксические позиции: финитный глагол является предикатом предложения, инфинитив — зависимым глагольной группы, а причастие функционирует входит в состав именной группы. Смешение этих форм в одной категории потенциально может скрывать различия в поведении людей и модели. PyMorphu3 разграничивает их, присваивая отдельные теги: VERB_fin (финитный глагол), INF (инфинитив), PTCP_full и PTCP_short (полное и краткое причастие), CONV (деепричастие). Аналогичное разграничение проводится для прилагательных: ADJ_full (полное) и ADJ_short (краткое).

5.6.2 Ранжированное пересечение POS@k

Данная метрика используется для проверки наиболее ожидаемых частей речи относительно контекста. Для этого для каждого контекста c части речи ранжировались по убыванию суммарной вероятности отдельно у людей и у модели, образуя два упорядоченных списка R_human_c и R_model_c . Метрика $POS_intersection@k$ вычислялась как доля совпавших тегов среди первых k позиций обоих списков:

$$POS_intersection@k(c) = |\{R_human_c[1:k]\} \cap \{R_model_c[1:k]\}| / k$$

При $k=1$ рассматривается совпадает ли наиболее вероятная часть речи у людей и у модели. При $k=5$ учитываются пять наиболее вероятных категорий.

5.6.3 Корреляция POS-распределений

Следующий алгоритм показывает в одних ли и тех же контексты люди и модели концентрируют предсказания на данной части речи. Для каждого частеречного тега t по всем 144 контекстам строились два вектора — суммарная вероятность тега t у людей в каждом контексте и аналогичная вероятность у модели:

$$h_t = (p_human(1,t), p_human(2,t), \dots, p_human(144,t))$$

$$m_t = (p_model(1,t), p_model(2,t), \dots, p_model(144,t))$$

Для каждой пары (h_t, m_t) вычислялись коэффициент Пирсона r и ранговый коэффициент Спирмена ρ . В анализ включались только теги, встретившиеся не менее чем в 10 контекстах, с ненулевым стандартным отклонением в обоих векторах. Высокое значение r означает, что там, где люди концентрируют вероятность на данном теге, то же делает и модель. Низкое или отрицательное значение означает, что контексты, в которых данная часть речи часто встречается у людей, для модели приводят к другим частям речи.

5.6.4 Анализ морфологических признаков

Помимо POS анализа, аналогичная логика была применена к отдельным морфологическим признакам: падежу (Case), числу (Number), роду (Gender), одушевлённости (Animacy), виду (Aspect), времени (Tense) и форме глагола (VerbForm). Значения признаков были извлечены при помощи stanza-разметки.

Для каждого признака f и каждого контекста c строились два вероятностных распределения по значениям признака: соответствующее предсказаниям людей и соответствующее предсказаниям модели. Например, для падежа в одном контексте может получиться распределение {Nom: 0.60, Gen: 0.30, Dat: 0.10} у людей и {Nom: 0.90, Gen: 0.10} у модели. К полученным матрицам применялся тот же алгоритм подсчета корреляции векторов для каждого признака. В анализ включались только те контексты, в которых хотя бы один из источников породил предсказание с данным признаком.

5.7 Метрики семантического уровня

Лексический анализ (раздел 5.5) фиксирует, совпадают ли конкретные словоформы или леммы, но не учитывает семантическую близость между предсказаниями. Два слова могут быть синонимами или гиперонимами и при этом не пересекаться на лексическом уровне. Семантический анализ показывает, насколько близки семантические пространства предсказаний людей и модели, даже если конкретные лексемы не совпадают.

Для семантического сравнения каждое предсказание (как от людей, так и от модели) было представлено статическим эмбедингом, полученным с помощью модели `ruwikiruscorpora` (архитектура `word2vec`), для этого каждое слово было закодировано в формате `lemma_UPOS`. Выбор статических эмбедингов обусловлен методологическими соображениями: статические векторные представления отражают дистрибутивное сходство лексем на основе их совместной встречаемости в больших корпусах, но не учитывают конкретный контекст употребления в предложении. Это делает их подходящим инструментом для сравнения семантических полей предсказаний в целом, а не их контекстуально-зависимых интерпретаций.

На предварительном этапе исследования была предпринята попытка использования контекстуальных эмбедингов, однако было установлено, что левый контекст предложения вносит доминирующий вклад в формирование векторного представления предсказания. В результате векторы семантически различных предсказаний оказывались практически идентичными, что делало сравнение неинформативным.

5.7.1 Метрика сравнения Centroid Similarity

Первая метрика — *Centroid Similarity* — вычисляется как косинусное сходство между двумя взвешенными средними векторами (центроидами распределений относительно каждого контекста): средним вектором облака человеческих ответов и средним вектором топ- k предсказаний модели. Для людей средний вектор вычислялся как средне-взвешенное значение эмбедингов всех уникальных ответов в данном контексте, где веса равны их вероятностям. Для модели центроиды рассчитывались аналогично при изменении параметра k , как это было описано в предыдущих разделах.

Данная метрика использовалась для оценки семантической близости между центрами человеческого и модельного распределений. Значения метрики лежат в диапазоне от -1 до 1 : значение 1 соответствует полному совпадению направлений векторов центроидов, а значение 0 указывает на их ортогональность и, соответственно, отсутствие семантического сходства.

5.7.2 Семантическое перекрытие распределений: Precision, Recall и F1

Для оценки семантического перекрытия двух облаков предсказаний использовался подход, основанный на поиске ближайшего соседа в пространстве эмбедингов. В отличие от *Centroid Similarity*, которая сводит оба распределения к двум усредненным векторам, этот подход сохраняет вклад каждого предсказания.

Recall показывает, насколько полно модель покрывает семантическое пространство человеческих ответов. Для каждого уникального ответа людей в заданном контексте вычислялось косинусное сходство со всеми топ- k предсказаниями модели, после чего выбиралось максимальное значение, соответствующее ближайшему соседу в пространстве эмбедингов. Ответ считался покрытым, если максимальное сходство превышало заданный порог θ , который с разной строгостью оценивает близость векторов. Итоговое значение *Recall* вычислялось как сумма вероятностей тех человеческих ответов, для которых среди предсказаний модели находился хотя бы один семантически близкий ответ. Таким образом, эта метрика в данном задании можно интерпретировать как вероятность того, что произвольный ответ человека, будет семантически покрытым хотя бы одним из топ- k предсказаний модели.

Метрика *Precision* определялась симметрично *Recall* и использовалась для оценки того, насколько предсказания модели соответствуют семантическому пространству человеческих ответов. Для каждого из топ- k предсказаний модели вычислялось максимальное косинусное сходство с эмбедингами человеческих ответов (опять в зависимости от прогового значения θ). Итоговое значение *Precision* вычислялось как сумма вероятностей тех предсказаний модели, для которых находился хотя бы один семантически близкое предсказание людей.

Таким образом, *Recall* характеризует полноту покрытия человеческого распределения модельными предсказаниями, а *Precision*, наоборот, отражает степень соответствия предсказаний модели человеческим ответам. Высокое значение полноты в сочетании с низкой точностью указывает на то, что модель делает множество предсказаний, некоторые из которых семантически близки к тем, что сделали люди, однако преобладающая часть предсказаний семантически далеко от человеческого распределения. Высокая точность при низкой полноте, напротив, свидетельствует о том, что модель даёт ограниченное число предсказаний, которые хорошо соответствуют части людских ответов, однако эта часть не покрывает всё разнообразие человеческих реакций.

На основе *Precision* и *Recall* вычислялся *F1* мера как их гармоническое среднее:

$$F1 = 2 \cdot Precision \cdot Recall / (Precision + Recall)$$

Гармоническое среднее демонстрирует высокую чувствительность к экстремально низким значениям любого из двух составляющих показателей: при стремлении *Precision* или *Recall* к нулю значение *F1* также стремится к нулю вне зависимости от величины второго показателя. Следовательно, *F1* обеспечивает интегральную оценку качества модели.

Анализ проводился при трёх порогах $\theta \in \{0.80, 0.90, 0.95\}$, отражающих уровни семантического сходства в пространстве word2vec: от умеренного до очень высокого. Предварительно, различные уровни порога были проверены экспериментально. Стабильность результатов на всех порогах указывает на стабильность выводов относительно выбора θ .

5.8 Способы анализа контекста

Метрики, описанные в разделах 5.4 – 5.7, позволяют охарактеризовать степень согласованности предсказаний между людьми и языковых моделей. Однако не менее важным остается вопрос о том, какие свойства контекста определяют, в каких именно случаях это согласование высоко, а в каких — нет. Один способ — это попытаться вручную оценить степень сложности контекста, разметить синтаксические и семантические ожидания, однако на данном этапе мы не успели этого сделать. Поэтому далее рассматриваются два подхода к оценке контекстных ожиданий, формируемых левым контекстом.

5.8.1 Энтропия контекста

Информационная энтропия Шеннона (Shannon 1948) — это мера неопределенности, которая вычисляется, как математическое ожидание количества информации:

$$H = -\sum_i p_i \ln p_i$$

где p_i — вероятность появления i символа или слова. В контексте нашего эксперимента $H = 0$ указывает на то, что контекст является закрытым (низкоэнтропийным), и люди сходятся в предсказании небольшого количества слов. Такие контексты предположительно характеризуются более жёсткими лексико-синтаксическими ограничениями: левый контекст с высокой степенью предопределяет и лексему, и её морфологические признаки. А открытые (высокоэнтропийные) контексты, с другой стороны, допускают широкий спектр грамматически и семантически приемлемых продолжений, что создаёт условия для расхождения между людьми и моделью: при слабых контекстных ограничениях вероятностные распределения людей и модели могут концентрироваться на разных частях речей или на разных семантических областях.

На основании значений энтропии контексты разбивались на четыре квантили ($Q1$ - $Q4$) — от наиболее закрытых к наиболее открытым. Это разбиение использовалось для

стратифицированного анализа: проверялось, как лексический overlap между предсказаниями модели и ответами людей изменяется в зависимости от степени закрытости контекста. Гипотеза состояла в том, что в закрытых контекстах ($Q1$) модели точнее воспроизводят человеческие ответы, поскольку жёсткие лексико-синтаксические ограничения сужают пространство допустимых продолжений, тогда как в открытых контекстах ($Q4$) распределения людей и модели могут расходиться сильнее.

5.8.2 Морфологические ограничения контекста

Второй подход основан на наблюдении, что морфологические характеристики целевого слова не произвольны — они задаются грамматической и семантической структурой левого контекста. Например, предлог в левой части жёстко определяет падеж зависимого существительного; вершина именной группы накладывает ограничения на согласование по роду, падежу и числу прилагательного. Поэтому мы также анализировали, насколько хорошо модели воспроизводят морфологические признаки целевого слова.

Для каждого предсказания модели проверялось совпадение с граммами целевого слова по шести признакам: падеж, число, род, время, вид и одушевлённость. Определялась доля предсказаний, совпавших с целевым значением признака, усреднённая по контекстам. Усреднение по контекстам, а не по предсказаниям, предотвращает искажение за счёт контекстов с большим числом предсказаний. Та же метрика вычислялась для ответов людей.

Анализ проводился только по тем контекстам, в которых целевое слово имело соответствующий признак — например, время анализировалось только для глагольных контекстов. Число контекстов варьировалось от 16 (время) до 141 (число), что отражает частотность соответствующих частей речи в выборке.

6. Результаты

6.1 Результаты на уровне целевых слов

Поскольку классификация контекста по типу попадания зависит от конкретной модели, результаты двух моделей рассматриваются отдельно (разделы 6.1.1 и 6.1.2 для GPT-4o-mini и Llama, соответственно, а также Таблицы 1 и 2 с результатами вычисления вероятностей для каждого типа контекстов). Для оценки согласованности классификаций дополнительно была построена матрица совпадений (Таблица 3).

6.1.1 Попадание в целевое слово; GPT-4o-mini

Корреляция между вероятностями целевого слова у людей и у GPT-4o-mini по всем 144 контекстам составляет $r = 0.881$ ($p < 0.001$) по Пирсону и $\rho = 0.755$ ($p < 0.001$) по

Спирмену. Это означает, что GPT-4o-mini в целом хорошо воспроизводит человеческие оценки предсказуемости целевого слова (см. Таблица 1).

Наиболее многочисленным классом является класс C4: в 86 из 144 контекстов ($\approx 60\%$) целевое слово не было предсказано ни людьми, ни моделью. Это подтверждает, что в большинстве контекстов удалённое слово не восстанавливается однозначно. Класс C1 включает 34 контекста, в которых оба источника предсказали целевое слово; средняя вероятность целевого слова при этом практически совпадает: 0.398 у людей и 0.378 у модели. Класс C2 содержит 22 контекста, где целевое слово предсказали только люди; средняя вероятность предсказания здесь составляет 0.099, что существенно ниже, чем в C1, — целевое слово в этих контекстах называли лишь единицы из участников эксперимента. Класс C3 представлен лишь 2 контекстами, что не позволяет делать качественных выводов.

Тип контекста	Кол-во контекстов	Средняя p_{human}	Средняя p_{model}
C1	34	0.398	0.378
C2	22	0.099	0.00
C3	2	0.00	0.092
C4	86	0.00	0.00

Таблица 1. Распределение средней вероятности предсказания целевого слова по типу контекста.
Модель: gpt4omini

6.1.2 Попадание в целевое слово; Llama

Корреляция между вероятностями целевого слова у людей и у Llama составляет $r = 0.423$ ($p < 0.001$) по Пирсону и $\rho = 0.594$ ($p < 0.001$) по Спирмену — существенно ниже, чем для GPT. Расхождение между линейной и ранговой корреляциями указывает на то, что Llama в целом различает лёгкие и трудные контексты (относительный порядок сохраняется), однако не концентрирует вероятностную массу на целевом слове так же, как GPT (см. Таблица 2).

Класс C4 по-прежнему остаётся наиболее многочисленным (77 контекстов, $\approx 53\%$), однако его доля ниже, чем у GPT-4o-mini (60%). Класс C3 насчитывает 11 контекстов — значительно больше, чем у GPT (2 контекста). Однако средняя вероятность модели в C3 составляет 0.0021. Уже на этом этапе это свидетельствует от том, что Llama распределяет вероятность между большим числом альтернатив.

Ключевое отличие Llama от GPT-4o-mini проявляется в классе C1: при том же числе контекстов (33 против 34) и близкой средней вероятности у людей (0.388 против 0.398)

средняя вероятность модели в C1 составляет для Llama лишь 0.0306. Это означает, что Llama формально «попадает» в целевое слово (оно присутствует в её распределении), но не выделяет его как доминирующее предсказание.

Тип контекста	Кол-во контекстов	Средняя p_human	Средняя p_model
C1	33	0.388	0.0306
C2	23	0.099	0.00
C3	11	0.00	0.0021
C4	77	0.00	0.00

Таблица 2. Распределение средней вероятности предсказания целевого слова по типу контекста.
Модель: Llama

6.2 Результаты лексических метрик

На лексическом уровне GPT демонстрирует относительно высокое совпадение с человеческими ответами уже при малых значениях k . В среднем $overlap@5$ составляет 0.216, а $overlap@20$ — 0.251. Дальнейшее увеличение числа учитываемых предсказаний практически не изменяет результат: при $overlap@100$ результаты выходят на плато, $overlap@400$ достигает лишь 0.259. Аналогичная динамика наблюдается и для surface-match метрики: при маленьких k достигается уже достаточно высокое перекрытие, а затем метрика быстро насыщается и перестает увеличиваться.

Такая картина свидетельствует о высокой концентрации распределения GPT: модель быстро выходит на плато и генерирует ограниченное множество лексем, совпадающих с человеческими ответами. При этом дальнейшее расширение списка предсказаний почти не увеличивает покрытие человеческого распределения.

В отличие от GPT, модель Llama демонстрирует существенно более медленный рост $overlap@k$. При малых k совпадение заметно ниже ($overlap@5 = 0.073$), однако по мере увеличения числа рассматриваемых предсказаний показатель продолжает расти: $overlap@100$ достигает 0.406, а $overlap@400$ — 0.490.

Таким образом, распределение Llama по сравнению с распределением GPT является более разреженным и менее концентрированным. Модель формирует более широкий набор предсказаний, в котором соответствие человеческим ответам проявляется лишь при сильном увеличении числа рассматриваемых ответов. Это согласуется с ранее отмеченной низкой вероятностью целевых слов: Llama редко выделяет отдельные человеческие ответы как наиболее вероятные, однако при расширении top-k постепенно охватывает

значительную часть человеческих предсказаний, достигает практически 50%, превышая по перекрытию GPT.

При сравнении лемматизированного и поверхностного распределений (см. Таблица 3) в обеих моделях *overlap@k* по леммам выше, чем совпадение по поверхностным формам. Это указывает на то, что часть расхождений между моделями и людьми связана не с выбором лексемы как таковой, а с различиями в морфологическом оформлении предсказаний.

k	Lemma overlap GPT	Lemma overlap Llama	Surface overlap GPT	Surface overlap Llama
5	0.216	0.073	0.200	0.059
10	0.245	0.132	0.230	0.113
15	0.249	0.176	0.235	0.146
20	0.251	0.204	0.236	0.172
50	0.257	0.305	0.237	0.249
100	0.258	0.406	0.238	0.340
200	0.259	0.482	0.238	0.411
400	0.259	0.490	0.238	0.436

Таблица 3. Результаты лексического перекрытия в зависимости от параметра k

6.3 Результаты синтаксических метрик

6.3.1 Результаты для POS_intersection@k

Модель GPT с разметкой rymorphy показывает наилучший результат совпадения (68,8%) для наиболее вероятной части респондентов (см. Таблица 4). Это означает, что в 69% контекстов модель правильно определяет ту грамматическую категорию, которую люди считают самой ожидаемой. При использовании универсальной разметки Stanza тот же показатель для GPT снижается до 59,7%. Для модели Llama разница между разными системами разметки минимальна (36,8% для Stanza vs 37,5% для rymorphy), что указывает на слабую чувствительность Llama к детализации тегов.

Модель	Система разметки	intersection @1	intersection @2	intersection @3	intersection @4	intersection @5
--------	---------------------	--------------------	--------------------	--------------------	--------------------	--------------------

GPT	Stanza	0,597	0,590	0,544	0,491	0,447
GPT	PyMorphy	0,688	0,582	0,506	0,426	0,372
Llama	Stanza	0,368	0,469	0,509	0,500	0,467
Llama	PyMorphy	0,375	0,483	0,512	0,512	0,496

Таблица 4. Средние значения POS_intersection@k для разных моделей

При увеличении числа учитываемых частей речи значения метрики для GPT уменьшаются, а для Llama сначала возрастают, а затем держатся на достаточно высоком уровне. Так, для GPT + PyMorphy3 *intersection@2* составляет 58,2%, а для *intersection@5* почти на 20% ниже — 37,2%. Для Llama + PyMorphy3 *intersection@2* равно 48,3%, а *intersection@5* – 49,6%. Сравнение моделей показывает, что GPT значительно превосходит Llama по точности предсказания единственной наиболее вероятной части речи (разница 0,313 для PyMorphy3). Однако уже при учёте трёх категорий значения сближаются (0,506 у GPT vs 0,512 у Llama для PyMorphy3), а при учёте пяти категорий Llama в большей мере совпадает с предсказанными частями речи людьми.

6.3.2 Результаты корреляционного анализа POS-распределений

В таблице 5 представлены коэффициенты корреляции Пирсона (r) и Спирмена (ρ) для тегов UPOS, имеющих ненулевую дисперсию в обоих векторах не менее чем в 10 контекстах.

Служебные части речи демонстрируют максимальное расхождение между моделями. GPT даёт высокие линейные корреляции для предлогов (ADP, $r = 0,83$), подчинительных (SCONJ, $r = 0,76$) и сочинительных союзов (CCONJ, $r = 0,71$), при умеренных, но значимых ранговых коэффициентах ($\rho = 0,40 - 0,45$). Llama же показывает значения, близкие к нулю (r от -0,002 до 0,031), что указывает на крайне низкую (почти нулевую) степень согласованности. Таким образом, GPT демонстрирует чувствительность к ограничениям служебных частей речи, а Llama — нет.

Части речи, представляющие из себя открытый синтаксический класс, также лучше предсказываются GPT. Существительные (NOUN) — категория, где преимущество GPT максимально ($r = 0,693$ против 0,194 у Llama). Для глаголов (VERB) и прилагательных (ADJ) GPT также превосходит вторую модель.

Числительные (NUM) имеют высокий коэффициент корреляции Пирсона у обеих моделей ($r > 0,89$). Местоимения (PRON) у Llama дают отрицательную линейную корреляцию (-0,017) при положительной ранговой (0,261), что указывает на нелинейную, но слабую монотонную связь. У GPT оба коэффициента положительны ($r = 0,343$, $\rho = 0,484$), что отражает лучшее различение контекстов, в которых предсказываются

местоимения. Междометия (INTJ) и частицы (PART) демонстрируют незначимые корреляции у обеих моделей, что объясняется их низкой частотностью.

Tag	GPT (r)	GPT (ρ)	Llama (r)	Llama (ρ)
NUM	0,937	0,616	0,898	0,226
ADP	0,830	0,408	0,002	0,136
SCONJ	0,761	0,400	0,031	0,373
CCONJ	0,711	0,448	-0,002	0,184
NOUN	0,693	0,825	0,194	0,305
VERB	0,556	0,629	0,416	0,524
PRON	0,343	0,484	-0,017	0,261
ADJ	0,529	0,385	0,121	0,181
ADV	0,428	0,343	0,267	0,312
PART	0,294	0,308	0,161	0,217
DET	0,262	0,410	0,184	0,282
INTJ	0,004	0,107	-0,031	0,087

Таблица 5. Коэффициенты корреляции Пирсона и Спирмена для различных частей речи;
Разметка: Stanza

В таблице 6 представлены коэффициенты корреляции Пирсона (r) и Спирмена (ρ) для тегов OpenCorpora, извлеченных при помощи анализатора PyMorphy3 и имеющих ненулевую дисперсию в обоих векторах не менее чем в 10 контекстах.

Рассматривая глагольную группу, GPT существенно превосходит Llama в предсказании инфинитива (INFN: r = 0,733 vs 0,553) и финитного глагола (VERB: r = 0,660 vs 0,387). Заметим, что у GPT линейная корреляция для инфинитива выше ранговой (0,733 vs 0,436), что указывает на нелинейную связь: абсолютные вероятности воспроизводятся хорошо, но порядок контекстов – хуже (то есть контексты, в которых предсказываются инфинитивы у модели и людей ранжируются по-разному). Для финитного глагола такого различия не наблюдается. Причастия (PRTF, PRTS) и деепричастия (GRND) показывают нулевые или отрицательные корреляции у обеих моделей. Таким образом, ни одна из моделей не улавливает грамматические ожидания, связанные с этими формами.

Для существительных (NOUN) GPT демонстрирует высокую ранговую корреляцию (ρ = 0,771) при умеренной линейной (r = 0,667), что свидетельствует о схожем ранжировании

контекстов. Llama заметно уступает ($r = 0,245$, $\rho = 0,344$). Полные (ADJF) и краткие прилагательные (ADJS) также предсказываются GPT лучше: разница по коэффициенту Пирсона r составляет 0,35–0,41. Интересно, что у GPT краткие прилагательные коррелируют выше полных (0,552 vs 0,413), что может быть связано с их специальным синтаксической позицией, в которой они могут стоять — предикативной.

Такая детализированная разметка позволяет сделать два ключевых вывода. Во-первых, высокая корреляция GPT, которая была найдена для VERB в UPOS ($r = 0,556$) на самом деле не однородная: инфинитивы (0,733) и финитные глагола (0,660) сохраняют высокие коэффициенты корреляции, но в причастиях наблюдается явное падение корреляции. Во-вторых, человеческие вероятностные ожидания в отношении причастных и деепричастных форм не воспроизводятся ни одной из моделей.

Ter	GPT (r)	GPT (ρ)	Llama (r)	Llama (ρ)
INFN	0,733	0,436	0,553	0,465
VERB	0,660	0,491	0,387	0,437
NOUN	0,667	0,771	0,245	0,344
ADJS	0,552	0,269	0,139	0,189
ADJF	0,413	0,412	0,060	0,223
ADVB	0,360	0,339	0,290	0,282
PRTS	0,247	0,125	0,061	0,261
PRTF	-0,035	0,127	-0,032	0,072
GRND	-0,006	0,143	-0,004	0,111
NUMR	0,937	0,616	0,812	0,084
PREP	-0,030	-0,063	0,023	-0,063

Таблица 6. Коэффициенты корреляции Пирсона и Спирмена для различных частей речи;
Разметка: PyMorphy3

6.3.3 Результаты кросс-корреляционного анализа POS-тегов

Для обнаружения систематических замен одной грамматической категории другой была построена перекрёстная корреляционная матрица (cross-correlation), в которой элемент $C[i,j]$ представляет собой коэффициент корреляции Пирсона между вектором вероятностей человека для тега i и вектором модели для тега j . Данная матрица выявляет, какой тег, выставленный моделью, максимально коррелирует с вероятностью данного тега

у людей, в том числе в случаях, когда эти теги не совпадают. На Рис. 1–4 можно видеть тепловые карты указанных матриц. Ниже приведены наиболее значимые результаты для каждой из матриц.

- *GPT x Stanza*

Положительные внедиагональные корреляции указывают на случаи категориального смещения между частями речи. Наиболее выраженная связь наблюдается между прилагательными в предсказаниях людей и частицами в предсказаниях модели (ADJ vs PART: $r = 0,38$), что может быть связано с их общей модифицирующей функцией. Также отмечаются корреляции между подчинительными союзами и детерминативами (SCONJ vs DET: $r = 0,28$), сочинительными и подчинительными союзами (CCONJ vs SCONJ: $r = 0,27$), а также между наречиями и союзами/частицами (ADV vs CCONJ: $r = 0,22$; PART vs ADV: $r = 0,22$), что отражает частичную функциональную близость в отдельных синтаксических позициях.

Отрицательные корреляции в основном фиксируются между глагольными и именными категориями, что отражает их чёткое противопоставление. Наиболее сильные смещения наблюдаются между глаголами и существительными (VERB vs NOUN: $r = -0,40$; NOUN vs VERB: $r = -0,36$), что указывает на довольно интересную дистрибутивную оппозицию. Дополнительно отрицательные связи были выявлены между наречиями и существительными (ADV vs NOUN: $r = -0,27$), существительными и частицами (NOUN vs PART: $r = -0,22$), а также существительными и предлогами (NOUN vs ADP: $r = -0,20$).




Рисунок 1. Матрица смешения для GPT x Stanza

- GPT x PyMorphy3

Более детальная частеречная разметка позволила выявить новые случаи смешений (см. Рисунок 2). Были найдены положительные внедиагональные корреляции, которые указывают на частичное смешение причастий и прилагательных ((PRTS vs ADJS: $r = 0,38$) и (ADJF vs PRTF: $r = 0,22$)), что объясняется их морфологической и синтаксической близостью в русском языке. Максимальная внедиагональная корреляция наблюдается между краткими прилагательными по множеству ответов людей и компаративами в предсказаниях модели (ADJS vs COMP: $r = 0,40$), что может быть связано с тем, что некоторые краткие формы прилагательных семантически сближаются со сравнительной степенью, из-за чего модель смещает вероятностные оценки в сторону компаративов. Дополнительно была выявлена корреляция между наречиями и краткими прилагательными (ADV vs ADJS: $r = 0,27$), что отражает их функциональную близость в предикативных конструкциях.

Как было показано в результатах предыдущего пункта, отрицательные корреляции в основном наблюдаются между глагольными и именными категориям. Наиболее сильная отрицательная связь зафиксирована между нефинитными глаголами и существительными

(VERB vs NOUN: $r = -0,34$). Похожие тенденции характерны и для инфинитивных форм, которые также противопоставляются существительным.




Рисунок 2. Матрица смещения для GPT x PyMorphy3

- Llama x Stanza

В разделе 6.3.2 для модели Llama уже были выявлены более низкие диагональные корреляции, чем у GPT, поэтому было неудивительно найти выраженные положительные внедиагональные корреляции, которые указывают на более частые смешения между грамматическими категориями (см. Рисунок 3). Наиболее высокая корреляция наблюдается между подчинительными союзами в человеческой разметке и детерминативами в предсказаниях модели (SCONJ vs DET: $r = 0,58$), что свидетельствует о недостаточно устойчивом разграничении служебных частей речи. Дифференциациях по служебным частям речи очень слабая (CCONJ vs ADV: $r = 0,42$; DET vs SCONJ: $r = 0,30$; DET vs CCONJ: $r = 0,30$). Связь между наречиями и глаголами (ADV vs VERB: $r = 0,27$), отсутствующая в результатах GPT, указывает на смешение адвербиальных и предикативных контекстов.

Отрицательные корреляции у Llama в целом менее выражены, чем у GPT. Наиболее сильная отрицательная связь фиксируется между существительными и глаголами (NOUN

vs VERB: $r = -0,35$), тогда как обратная корреляция между глаголами и существительными выражена слабее (VERB vs NOUN: $r = -0,22$). Это указывает на то, что Llama чуть лучше согласуется в разграничении контекстов, в которых люди предпочитают существительные (или глаголы), чем GPT.

Результаты кросс-корреляционного анализа Llama x Stanza показывают наличие систематических смещений, прежде всего между служебными частями речи, а также между наречиями и глаголами.




Рисунок 3. Матрица смещения для Llama x Stanza

- Llama x PyMorphy

Положительные внедиагональные корреляции для комбинации Llama x PyMorphy3 свидетельствуют о смещении морфологически близких категорий. Как и для GPT, наиболее сильные связи наблюдаются между краткими причастиями и краткими прилагательными (PRTS vs ADJS: $r = 0,55-0,56$), при этом по сравнению с GPT эти корреляции выражены еще выше, что говорит о более высоком смещении контекстов.

Дополнительно положительные корреляции фиксируются между глаголами и предикативами (VERB vs PRED: $r = 0,28$), глаголами и компаративами (VERB vs COMP: r

= 0,27), инфинитивами и союзами (INFN vs CONJ: $r = 0,25$), а также числительными и предлогами (NUMR vs PREP: $r = 0,25$), такие смешение для GPT были выражены слабее.

Отрицательные корреляции выражены слабее и в основном отражают уже описанное противопоставление именных и глагольных контекстов. Так, существительные отрицательно коррелируют с глаголами (NOUN vs VERB: $r = -0,20$), а наречия — с существительными (ADVB vs NOUN: $r = -0,21$).




Рисунок 4. Матрица смешения для Llama x PyMorphu3

6.3.4 Результат корреляционного анализа на уровне морфологических признаков

В таблице 7 приведены коэффициенты корреляции Пирсона и Спирмена для каждого значения морфологических признаков.

- *Падеж*

GPT демонстрирует высокие линейные корреляции для косвенных падежей (Ins 0,846, Loc 0,832, Dat 0,792) и умеренные для Gen (0,643) и Acc (0,369). Именительный падеж (Nom) коррелирует слабее всего (0,198). Ранговые корреляции Спирмена у GPT для падежей заметно ниже линейных, что указывает на нелинейную связь: абсолютные

вероятности воспроизводятся хорошо, но порядок контекстов сохраняется лишь частично. У Llama корреляции значительно ниже: максимальная – для Dat ($r = 0,588$), остальные от 0,17 до 0,44. Интересно, что у Llama ранговые корреляции иногда выше линейных (Ass: $r = 0,414$, $\rho = 0,477$; Nom: $r = 0,380$, $\rho = 0,355$), что свидетельствует о лучшем ранжировании контекстов.

- *Одушевлённость*

GPT показывает высокие корреляции как для параметра неодушевлённость ($r = 0,702$, $\rho = 0,822$), так и для одушевлённости ($r = 0,696$, $\rho = 0,314$). У Llama корреляции низкие (Inan: $r = 0,280$, $\rho = 0,386$; Anim: $r = 0,087$, $\rho = 0,306$), что говорит о плохом различении этого семантического признака.

- *Род*

GPT хорошо различает женский ($r = 0,729$, $\rho = 0,784$), мужской ($r = 0,665$, $\rho = 0,778$) и средний род ($r = 0,607$, $\rho = 0,632$). Оба коэффициента близки, что указывает на линейную связь. Llama демонстрирует умеренные корреляции для женского и мужского рода ($r \approx 0,33$ – $0,34$, $\rho \approx 0,35$ – $0,40$) и практически нулевую линейную связь для среднего рода ($r = 0,064$) при слабой ранговой ($\rho = 0,215$).

- *Число*

У GPT корреляции для единственного числа выше ($r = 0,543$, $\rho = 0,708$), чем для множественного ($r = 0,439$, $\rho = 0,593$). У Llama оба значения низкие ($r \approx 0,19$ – $0,24$, $\rho \approx 0,26$).

- *Время*

У GPT прошедшее ($r = 0,434$, $\rho = 0,690$) и настоящее ($r = 0,386$, $\rho = 0,613$) времена коррелируют умеренно, будущее – незначимо ($r = -0,053$, $\rho = 0,015$) из-за малого числа контекстов, в которых хоть кто-то предсказал форму в будущем времени ($n = 29$). У Llama будущее время показывает неожиданно высокую линейную корреляцию ($r = 0,533$), но очень низкую ранговую ($\rho = 0,132$), что указывает на артефакт малой выборки: средние значения воспроизводятся, а порядок – нет.

- *Вид*

Несовершенный вид у GPT коррелирует лучше ($r = 0,653$, $\rho = 0,765$), чем совершенный ($r = 0,459$, $\rho = 0,548$). У Llama оба значения ниже ($r \approx 0,31$ – $0,42$, $\rho \approx 0,38$ – $0,61$). Высокие ранговые коэффициенты у GPT (0,765) свидетельствуют о хорошем различии видовых контекстов.

- Форма глагола

GPT лучше коррелирует с людьми, чем Llama по инфинитиву ($r = 0,748$, $\rho = 0,622$) и финитной форме ($r = 0,634$, $\rho = 0,739$). Причастия и деепричастия у обеих моделей практически не коррелируют линейно ($r \approx 0$ или отрицательные), однако ранговые коэффициенты у GPT для причастий ($\rho = 0,470$) и деепричастий ($\rho = 0,224$) выше, чем линейные, что указывает на слабую монотонную связь (порядок контекстов ещё как-то сохраняется, но абсолютные вероятности – нет). При этом для обеих моделей присуща одна и та же тенденция по согласованности с людьми.

Признак	Значение	GPT (r)	GPT (ρ)	Llama (r)	Llama (ρ)
Падеж	Ins	0,846	0,248	0,169	0,231
	Loc	0,832	0,378	0,440	0,366
	Dat	0,792	0,316	0,588	0,228
	Gen	0,643	0,451	0,241	0,284
	Acc	0,369	0,319	0,414	0,477
	Nom	0,198	0,115	0,380	0,355
Одушевленность	Inan	0,702	0,822	0,280	0,386
	Anim	0,696	0,314	0,087	0,306
Род	Fem	0,729	0,784	0,344	0,404
	Masc	0,665	0,778	0,329	0,348
	Neut	0,607	0,632	0,064	0,215
Число	Sing	0,543	0,708	0,235	0,264
	Plur	0,439	0,593	0,189	0,257
Время	Past	0,434	0,690	0,367	0,371
	Pres	0,386	0,613	0,358	0,479
	Fut	-0,053	0,015	0,533	0,132
Аспект	Imp	0,653	0,765	0,417	0,606
	Perf	0,459	0,548	0,306	0,383
Форма глагола	Inf	0,748	0,622	0,597	0,604
	Fin	0,634	0,739	0,394	0,569

	Part	0,101	0,470	0,039	0,184
	Conv	-0,011	0,224	-0,09	0,203

Таблица 7. Коэффициенты Пирсона и Спирмена для корреляции с морфологическими признаками

В таблице 8 приведены средние значения корреляции Пирсона по каждому признаку (усреднение по всем значениям признака). GPT имеет более высокие средние корреляции по всем признакам, кроме времени. Наибольшее преимущество GPT – по роду (0,667 vs 0,246), одушевлённости (0,699 vs 0,184) и падежу (0,613 vs 0,372). При этом Llama более скоррелирована по времени глагола (0,429 vs 0,256).

Признак	GPT mean_r	Llama mean_r
Падеж	0,613	0,372
Одушевленность	0,699	0,184
Число	0,491	0,212
Род	0,667	0,246
Время	0,256	0,429
Аспект	0,556	0,362
Форма глагола	0,368	0,255

Таблица 8. Среднее значение коэффициента Пирсона для каждого обобщенного признака

Сравнение коэффициентов Пирсона и Спирмена выявляет важные закономерности. Для многих признаков (падежи, число, время) ранговые корреляции GPT значительно выше линейных, что указывает на нелинейную связь: модель хорошо сохраняет порядок контекстов по степени ожидаемости данного значения, но абсолютные вероятности сжаты или сдвинуты (типично для калибровки вероятностей). У Llama, напротив, для многих признаков линейные и ранговые корреляции близки, но сами значения коэффициентов низки, но есть категории, в которых эта модель более скоррелирована с людьми, чем GPT.

6.3.5 Обобщенные выводы синтаксических метрик

В данном разделе находится обобщенные выводы для синтаксического уровня сравнения.

- GPT лучше согласуется с людьми по грамматическим ожиданиям. Это проявляется как в точности предсказания наиболее вероятной части речи ($\text{intersection@1} = 0.69$ vs 0.38 у Llama), так и в более высоких корреляциях POS-распределений —

особенно для служебных слов, а также для большинства морфологических признаков. При этом GPT хорошо воспроизводит не только то, *какая* категория ожидается, но и *в каких* контекстах — о чём свидетельствуют высокие ранговые корреляции для падежа, числа и рода.

- Llama плохо улавливает ограничения служебных частей речи (корреляции около нуля для ADP, SCONJ, CCONJ), которые замечают люди. Модель также показывает более частые смещения между категориями в кросс-корреляционных матрицах и имеет низкие корреляции по большинству морфологических признаков. Интересное исключение — время глагола, где Llama в среднем более скоррелирована с людьми, чем GPT (0.429 vs 0.256).
- Единственная область, где Llama незначительно превосходит GPT — широкое покрытие частей речи при больших k.
- Отдельного стоит отметить результат по причастиям и деепричастиям: ни одна из моделей не воспроизводит ожидания людей относительно этих форм ни по линейной, ни по ранговой корреляции. Скорее всего это связано с тем, что причастия и деепричастия занимают специфические синтаксические позиции, которые чувствуют люди (и поэтому без труда предсказывают эти части речи, но которые при сложно предсказать моделям без глубокого понимания структуры именной и глагольной группы.

6.4 Результаты семантических метрик

6.4.1 Результат метрики Centroid Similarity

GPT-4o-mini демонстрирует значительно более высокое сходство семантических центроидов с человеческими ответами по сравнению с Llama (см. таблицу 9). При этом у обеих моделей рост значения метрики замедляется после top-5, что позволяет предположить, что семантический центр распределения в основном определяется наиболее вероятными предсказаниями модели. Увеличении параметра k в два раза со 100 до 200, не дает никакого значимого изменения.

top-k	GPT	Llama
1	0,574	0,269
5	0,688	0,353
10	0,696	0,361
20	0,699	0,364
50	0,701	0,368

100	0,702	0,370
200	0,702	0,371

Таблица 9. Значение метрики Centroid Similarity при изменении параметра k

6.4.2 Результат метрик Precision, Recall и F1

Модели демонстрируют различный характер предсказаний по рассмотренным в данном разделе метрикам (см. Таблица 10; значения приведены при $k = 10$). GPT-4o-mini характеризуется высоким значением Precision, при это значение Recall сильно ниже: предсказания данной модели в большей степени семантически соответствуют человеческим ответам, однако модель не перекрывает всё семантическое облако ответов людей. В то же время Llama показывает противоположную тенденцию: с увеличением k значение Recall возрастает и достигает около 22% покрытия, тогда как Precision остаётся низким (0,05 – 0,07) вне зависимости от увеличения θ . Это свидетельствует о том, что Llama генерирует более широкий набор предсказаний, среди которых встречаются семантически близкие к человеческим ответам слова, однако значительная часть предсказаний остаётся семантически далекими от предсказаний людей. Кроме того, значения метрик для GPT-4o-mini остаются стабильными при изменении порога θ : Recall варьируется в пределах 0,386–0,387, Precision — 0,597 – 0,604, а F1 — 0,427 – 0,431. Аналогичная устойчивость наблюдается и у Llama, однако её показатели существенно ниже.

θ	GPT Recall	GPT Prec.	GPT F1	Llama Recall	Llama Prec.	LLama F1
0,80	0,387	0,604	0,431	0,219	0,065	0,062
0,90	0,386	0,599	0,429	0,218	0,057	0,058
0,95	0,386	0,597	0,427	0,218	0,057	0,058

Таблица 10. Значения метрика Precision, Recall и F1 в зависимости от изменения θ

Метрика F1 отражает соотношение между полнотой и точностью предсказаний моделей. У GPT её значения выше и составляют около 0,43, тогда как у Llama F1 остаётся на уровне около 0,06 при всех значениях порога.

Также рассмотрим результаты, приведенные в таблице 11. С увеличением значения k показатели GPT остаются практически неизменными: Recall возрастает с 0,386 до 0,396, а Precision сохраняется на уровне около 0,595–0,599. Это указывает на устойчивость семантического распределения модели: расширение числа предсказаний практически не добавляет новых семантически релевантных предсказаний.

Для Llama наблюдается иная тенденция. При увеличении k Recall существенно возрастает — с 0,218 при top-10 до 0,489 при top-100, что свидетельствует о том, что среди менее вероятных предсказаний встречаются те, которые семантически похожи на непокрытые предсказания людей. Однако одновременно Precision снижается с 0,057 до 0,041, что указывает на рост числа семантически нерелевантных предсказаний.

В целом результаты подтверждают, что GPT, относительно предсказаний людей, формирует более компактное и семантически согласованное пространство предсказаний, тогда как Llama демонстрирует более широкое, но менее точное распределение ответов.

k	GPT Recall $\theta = 0,9$	GPT Prec. $\theta = 0,9$	Llama Recall $\theta = 0,9$	Llama Prec. $\theta = 0,9$
10	0.386	0.599	0.218	0.057
50	0.395	0.595	0.4000	0.045
100	0.396	0.595	0.489	0.041

Таблица 11. Значения метрика Precision, Recall и F1 в зависимости от изменения θ

Таким образом, по совокупности семантических метрик можно сделать вывод, что GPT точнее воспроизводит семантическое пространство предсказаний людей.

6.5 Результаты анализа контекста

6.5.1 Результат влияния энтропии контекста

Среднее значение энтропии по 144 контекстам составило $H = 2.18$ ($SD = 0.84$), медиана — 2.26. Распределение близко к нормальному с небольшой левой асимметрией, то есть, если ориентироваться на предсказания людей, то можно выявить небольшое смещение в сторону более открытых контекстов. Диапазон значений широкий: от $H \approx 0$ до $H = 3.77$, что говорит нам о том, что контексты на которых проводился эксперимент достаточно хорошо сбалансированы по сложности обработки для людей.

Рассмотрим результаты, приведенные в таблице 12. Разбиение по квартилям хорошо иллюстрирует возрастание сложности контекстов. Чем выше значение энтропии, тем больше различных предсказаний люди начинают приводить (6.8 для Q1 мы 38.3 для Q4). Таким образом, открытые контексты принципиально другим режимом предсказания: люди не сходятся ни на каком доминирующем ответе.

Квартиль	H_{mean}	Среднее кол-во предсказаний (людей)	Примеры контекстов
Q1	1.06	6.8	Дорога ведет в глухой

			Причиной аварии был мобильный ____
Q2	1.97	10.9	Приготовь себе диетические овощные блюда, ____ В котёл бросают куски ____
Q3	2.49	17.9	В деревнях по-прежнему ____ Вспоминая ____
Q4	3.20	38.3	Тому, кто ____ В речи учёного прозвучало ____

Таблица 12. Разбиение контекстов на квартили относительные значения энтропии

Анализ по квартилям показал (см. Таблица 13), что с увеличением энтропии контекста (то есть, чем контекст для людей является более открытым и менее предсказуемым) лексический overlap между предсказаниями моделей и ответами людей постепенно снижается у обеих моделей при всех значениях k .

GPT демонстрирует высокие значения overlap уже при небольших k (практически 50%), однако дальнейшее увеличение числа предсказаний почти не влияет на результат: значения растут медленно, что указывает на быстрое насыщение модели. Это означает, что GPT концентрируется на сравнительно узком наборе наиболее вероятных лемм. При этом перекрытие в квартилях Q2-Q4 значительно ниже, чем в наиболее закрытом квартиле Q1.

Как и с другими лексическими метриками Llama показывает противоположную динамику относительно GPT. При top-10 значения overlap заметно ниже, чем у GPT, однако при увеличении k рост перекрытия продолжает расти. В Q1 overlap возрастает с 0,243 при top-10 до 0,584 при top-100, а в Q4 — с 0,045 до 0,255. Таким образом, как уже было показано, Llama распределяет предсказания по более широкому лексическому пространству и при больших k охватывает больше человеческих ответов.

В результате GPT превосходит Llama при небольших значениях k , тогда как при top-50 и top-100 Llama начинает покрывать значительно больше человеческих предсказаний, особенно в закрытых контекстах (Q1). При этом даже максимальное значение overlap остаётся относительно невысоким и далеко не покрывает всего многообразия предсказаний людей (0,584). Это говорит о том, что даже в наиболее предсказуемых контекстах модели воспроизводят лишь часть лексики, используемой людьми.

Квартиль	GPT overlap@10	GPT overlap@50	GPT overlap@100	Llama overlap@10	Llama overlap@50	Llama overlap@100
Q1	0,425	0,435	0,435	0,243	0,493	0,584
Q2	0,284	0,288	0,288	0,157	0,326	0,427
Q3	0,168	0,181	0,185	0,085	0,251	0,361
Q4	0,102	0,122	0,126	0,045	0,152	0,255

Таблица 13. Изменение значения метрики overlap@k в зависимости от изменения квартиля и значения параметра k

6.5.1 Результат анализа предсказуемости морфологических параметров целевого слова

По всем шести признакам люди превосходят обе модели (см. Таблица 14). Наименьшее расхождение между людьми и моделями наблюдается по числу и виду — признакам, которые, наиболее жёстко задаются контекстом. Наибольшее расхождение фиксируется по падежу и одушевлённости.

При этом поведение двух моделей при сравнении между собой опять отличается. GPT-4o-mini значительно точнее воспроизводит глагольные категории: вид (0.425 vs 0.299) и время (0.419 vs 0.291). В то время как Llama незначительно превосходит GPT по числу (0.609 vs 0.588) и роду (0.392 vs 0.363). Принципиально важно отметить результаты по предсказанию падежа: Llama воспроизводит падеж целевого слова лучше, чем GPT (0.357 vs 0.282), несмотря на то что по большинству других показателей Llama уступает. Это может объясняться тем, что широкое и разнообразное распределение предсказаний Llama покрывает больше падежных форм, среди которых чаще оказывается целевая.

В целом результаты согласуются с картиной, полученной на лексическом и семантическом уровнях: модели улавливают наиболее очевидные морфологические ограничения контекста, однако систематически уступают людям, особенно по признакам с более широким пространством возможных значений.

Признак	Люди	GPT	Llama
Число	0,706	0,588	0,609
Одушевленность	0,652	0,344	0,368
Род	0,539	0,363	0,392
Падеж	0,699	0,282	0,417
Вид	0,495	0,425	0,299

Время	0,643	0,419	0,291
-------	-------	-------	-------

Таблица 14. Предсказуемость различных морфологических параметров таргетного слова

7. Выводы

Настоящее исследование было посвящено методологическому вопросу: в какой мере вероятностные распределения предсказаний больших языковых моделей соответствуют предсказаниям людей в парадигме cloze-теста. В отличие от подходов, сравнивающих лишь точечные предсказания, предложенная методология позволяет сопоставить полные вероятностные распределения на лексическом, морфосинтаксическом и семантическом уровнях. Ключевым техническим решением стал модифицированный алгоритм beam search, обеспечивающий извлечение широкого набора кандидатов с сохранением их вероятностей.

Полученные результаты позволяют ответить на центральный вопрос о потенциале замены людей большими языковыми моделями при сборе норм предсказуемости — однако ответ нужно сформулировать аккуратно, опираясь на разные уровни анализа, потому что поведение моделей различается в зависимости от глубины сравнения.

На лексическом уровне полная замена невозможна. Максимальное значение метрики overlap@k с человеческими ответами у GPT-4o-mini быстро выходит на плато около 25–26%, тогда как у Llama он достигает 49% лишь при top-400 взятых предсказаний. Даже в наиболее предсказуемых и закрытых контекстах (Q1) максимальное покрытие не превышает 58%. Это означает, что значительная доля человеческих ответов остаётся за пределами распределений обеих моделей при любом числе кандидатов. Схожую картину даёт семантический анализ: F1-мера у GPT составляет 0.43, у Llama — 0.06. Таким образом, ни одна из моделей не способна воспроизвести полное семантическое разнообразие человеческих предсказаний. Однако, если перед исследователями стоит задача не полного воспроизведения человеческих распределений, а лишь предварительного отбора стимульного материала или быстрой оценки того, насколько предсказуем тот или иной контекст, модель GPT-4o-mini представляет собой вполне пригодный инструмент: высокая корреляция с человеческими вероятностями целевого слова ($r = 0.88$ по Пирсону) позволяет надёжно ранжировать контексты по степени закрытости и отсеивать слишком неоднозначные или, напротив, слишком легкие и предсказуемые предложения ещё до проведения дорогостоящего эксперимента с участниками (в то время как Llama уступает в данной задаче).

На морфосинтаксическом уровне картина гораздо более интересная. GPT демонстрирует высокую согласованность с людьми по большинству морфологических

категорий: корреляции для падежа (творительный $r = 0.846$, местный $r = 0.832$, дательный $r = 0.792$), рода ($r = 0.61–0.73$), числа ($r = 0.44–0.54$) и вида ($r = 0.46–0.65$) указывают на то, что модель правильно улавливает грамматические ограничения, которые левый контекст накладывает на следующее слово. Показательна и высокая точность предсказания наиболее ожидаемой части речи: $\text{intersection@1} = 0.69$ для GPT vs 0.38 для Llama. Именно поэтому GPT может также рассматриваться как реальный инструмент для предварительной оценки морфосинтаксических ожиданий: определения того, какую часть речи ожидают люди в данном контексте (и в какой форме она должна стоять). Исключение составляет предсказание причастий и деепричастий — ни одна из моделей не воспроизводит соответствующие ожидания людей ($r \approx 0$ или отрицательные значения).

Таким образом, вопрос о применимости LLM в качестве замены людям при сборе норм предсказуемости всё ещё остаётся открытым. Полная замена на сегодняшний день невозможна: ни одна из исследованных моделей не воспроизводит лексическое или семантическое разнообразие человеческих предсказаний. Вместе с тем GPT-4o-mini представляет собой надёжный инструмент для задач, где требуется узнать какие-то структурные характеристики стимулов, контекста или ожиданий людей.

В будущем исследовании можно добавить в анализ русские монолингвальные модели, а также расширить выборку стимульного материала — включить больше контекстов с различной степенью предсказуемости, разными жанрами текстов и синтаксическими конструкциями. Также было бы очень интересно узнать насколько результаты зависят от промпта, так как современные модели могут вести себя совершенно иначе в зависимости от разных формулировок заданий.

Библиография

1. Ashby, J., Rayner, K., & Clifton, C. (2005). Eye movements of highly skilled and average readers: differential effects of frequency and predictability. *Quarterly Journal of Experimental Psychology*, 58(6), 1065–1086.
2. Alexeeva, S., Slioussar, N., & Chernova, D. (2018). StimulStat: A lexical database for Russian. *Behavior Research Methods*, 50(6), 2305–2315.
3. Belinkov, Y., Mueller, A., Kim, N., Mohebbi, H., Chen, H., Arad, D., & Sarti, G. (2025, November). Proceedings of the 8th BlackboxNLP Workshop: Analyzing and Interpreting Neural Networks for NLP. In *Proceedings of the 8th BlackboxNLP Workshop: Analyzing and Interpreting Neural Networks for NLP*.
4. Ehrlich, S. F., & Rayner, K. (1981). Contextual effects on word perception and eye movements during reading. *Journal of Verbal Learning & Verbal Behavior*, 20(6), 641–655.
5. Frank, S. L., Otten, L. J., Galli, G., & Vigliocco, G. (2013). Word surprisal predicts N400 amplitude during reading.
6. Hale, J. (2001). A probabilistic Earley parser as a psycholinguistic model. *Proceedings of NAACL 2001*.
7. Ilia, E., & Aziz, W. (2024). Predict the next word. In *Proceedings of the 18th EACL* (Vol. 2, pp. 234–255).
8. Jacobs, C. L., Grobol, L., & Tsang, A. (2024). Large-scale cloze evaluation reveals that token prediction tasks are neither lexically nor semantically aligned. *arXiv preprint arXiv:2410.12057*.

9. Laurinavichyute, A. K., Sekerina, I. A., Alexeeva, S., et al. (2019). Russian Sentence Corpus: Benchmark measures of eye movements in reading in Russian. *Behavior Research Methods*, 51, 1161–1178.
10. Levy, R. (2008). Expectation-based syntactic comprehension. *Cognition*, 106(3), 1126–1177.
11. Lopes Rego, A. T., Snell, J., & Meeter, M. (2024). Language models outperform cloze predictability in a cognitive model of reading. *PLOS Computational Biology*, 20(9), e1012117.
12. Lyu, B. et al. (2024). Finding structure during incremental speech comprehension. *ELife*, 12, RP89311.
13. Merx, D., & Frank, S. L. (2020). Human sentence processing: Recurrence or attention? *arXiv:2005.09471*.
14. Lopukhina, A., Laurinavichyute, A., Sekerina, I. A., Dragoy, O., & Toldova, S. (2021). Normy predskazuyemosti russkikh predlozheniy: ot czloze-testa k modelyam. [Data set, Russian Sentence Corpus norms]. Tsentr yazyka i mozga NIU VShE.
15. Nentcheva, L., Schuster, S., & Santi, A. (2025). Surprise! LM-generated surprisal values cannot fully account for human parsers' preferences in relative clause comprehension. *Human Sentence Processing Conference*.
16. Nikiforova, A., Pletenev, S., Sinitsyna, D., Sorokin, S., Lopukhina, A., & Howell, N. (2020). Language models for cloze task answer generation in Russian. *Proceedings of the Second Workshop on Linguistic and Neurocognitive Resources*, 28–37.
17. Oh, B. D., & Schuler, W. (2023, December). Transformer-based language model surprisal predicts human reading times best with about two billion training tokens. In *Findings of the association for computational linguistics: EMNLP 2023* (pp. 1915-1921).
18. Rayner, K. (1998). Eye movements in reading and information processing: 20 years of research. *Psychological Bulletin*, 124(3), 372–422.
19. Shannon C. E. A mathematical theory of communication //The Bell system technical journal. – 1948. – T. 27. – №. 3. – С. 379-423.
20. Smith N. J., Levy R. The effect of word predictability on reading time is logarithmic //Cognition. – 2013. – T. 128. – №. 3. – С. 302-319.
21. Taylor, W. L. (1953). Cloze procedure: A new tool for measuring readability. *Journalism Quarterly*, 30, 415–433.
22. Wilcox, E. G., Gauthier, J., Hu, J., Qian, P., & Levy, R. (2020). On the predictive power of neural language models for human real-time comprehension behavior. *arXiv preprint arXiv:2006.01912*.
23. Gotlieb Wilcox, E., Pimentel, T., Meister, C., Cotterell, R., & Levy, R. P. (2023). Testing the Predictions of Surprisal Theory in 11 Languages. *arXiv e-prints*, arXiv-2307.

Приложения

Приложение 1. Результаты курсовой работы второго курса

Рисунок 1. Общие результаты по семантической приемлемости .




Рисунок 2. Общие результаты по грамматической корректности.




Рисунок 3. Соотношение приемлемых предсказаний моделей в зависимости от попадания в ожидаемую часть речи.




Рисунок 4. Соотношение приемлемых предсказаний людей в зависимости от попадания в ожидаемую часть речи.




Рисунок 5. Зависимость точности предсказаний людей в зависимости от длины таргетного слова.




Рисунок 6. Зависимость точности предсказаний моделей в зависимости от длины таргетного слова.




Рисунок 7. Зависимость точности предсказаний людей в зависимости от частотности таргетного слова.




Рисунок 6. Зависимость точности предсказаний моделей в зависимости от частотности таргетного слова.





Рисунок 7. Общие результаты по семантической и грамматической разметкам.



Приложение 2. Код beam search для GPT

```

1 def generate_beams_openai(initial_context: str, max_length=8):
2     BeamState = namedtuple('BeamState', ['current_text', 'token_path', 'score_trace', 'finished'])
3
4     def expand_beam(bean_state):
5         """Expand a single beam by getting top next tokens"""
6         current_text, token_path, score_trace, finished = bean_state
7
8         # Проверяем, не нужно ли остановить бим
9         if len(token_path) <= 1:
10             pass
11         elif (check_result := check_beam(token_path, max_length)):
12             print(f'Остановили beam, причина: {check_result}, получилось {" ".join(token_path)}')
13             return BeamState(current_text, token_path, score_trace, check_result)
14
15         try:
16             log_probs = fetch_log_probs_openai(current_text)
17             next_tokens = sorted(log_probs.items(), key=lambda x: x[1], reverse=True)
18             new_beams = []
19
20             for token, prob in next_tokens:
21                 new_text = f'{current_text}{token}'
22                 new_path = token_path + [token]
23                 new_score_trace = score_trace + [prob] # accumulate probability
24                 new_beams.append(BeamState(new_text, new_path, new_score_trace, False))
25             return new_beams
26
27         except Exception as e:
28             print(f'Ошибка при генерации: {e}')
29             traceback.print_exc()
30             return [bean_state]
31
32     # Start with initial beam
33     active_beams = [BeamState(initial_context, [], [], False)]
34     completed_beams = []
35
36     # Expand beams until all are completed
37     while active_beams:
38         beam = active_beams.pop(0)
39         expanded = expand_beam(bean)
40
41         for new_beam in expanded:
42             current_text, token_path, score_trace, finished = new_beam
43             if finished:
44                 completed_beams.append(new_beam)
45             else:
46                 active_beams.append(new_beam)
47
48     return completed_beams

```

Приложение 3. Код beam search для Llama

```

1 def beam_search_completions3(sentence, tokenizer, model,
2                             max_depth=19, beam_width=100, min_prob=1e-6,
3                             cyrillic_token_ids=None, new_id_to_old_id=None,
4                             token_cache=None, device=None):
5     """
6     Beam search с учётом сепараторов и мультитокеновых слов.
7     Условия:
8     1) Если первый токен начинается с сепаратора – убираем сепаратор и продолжаем генерацию.
9     2) Если не первый токен и начинается с сепаратора – сохраняем текущее слово и прекращаем генерацию.
10    3) Если токен – только сепаратор – прекращаем генерацию.
11    4) Если сепаратор в конце токена – буквенную часть добавляем к слову и прекращаем генерацию.
12    """
13    if "<mask>" not in sentence:
14        return None
15
16    prefix, suffix = sentence.split("<mask>", 1)
17    inputs = tokenizer(prefix.strip(), return_tensors="pt")
18    inputs = {k: v.to(device) for k, v in inputs.items()}
19    input_ids = inputs["input_ids"]
20
21    cyrillic_token_ids_tuple = tuple(cyrillic_token_ids)
22    completed_words, word_details = {}, {}
23
24    def save_word(tokens, probs, prob, depth, stop_reason, sep_prob=None):
25        """Helper: save completed word if valid and better than existing one."""
26        word_str = ''.join([token_cache[t]['str'] for t in tokens])
27        if is_single_cyrillic_word(word_str):
28            if word_str not in completed_words or prob > completed_words[word_str]:
29                completed_words[word_str] = prob
30                word_details[word_str] = {
31                    'tokens': tokens.copy(),
32                    'probs': probs.copy(),
33                    'depth': depth,
34                    'stop_reason': stop_reason,
35                    'separator_probability': sep_prob
36                }
37
38    beams = [(input_ids, [], [], 1.0, 0)] # (ids, tokens, probs, seq_prob, depth)
39
40    for depth in range(max_depth):
41        if not beams:
42            break
43
44        new_beams = []
45        for ids, word, word_probs, seq_prob, d in beams:
46            next_probs = get_next_token_probs(tuple(ids.squeeze().tolist()),
47                                             cyrillic_token_ids_tuple, model, device)
48            for reduced_id in np.argsort(next_probs)[-beam_width:][::-1]:
49                prob = next_probs[reduced_id]
50                total_prob = seq_prob * prob
51                if total_prob < min_prob:
52                    continue
53
54                token_id = new_id_to_old_id[reduced_id]
55                token_info = token_cache[token_id]
56                if not token_info['is_valid']:
57                    continue
58
59                token_str = token_info['str']
60                new_ids = torch.cat([ids, torch.tensor([token_id], device=device)], dim=1)
61
62                sep_start = token_str[0] if token_str and token_str[0] in SEPARATORS else None
63                sep_end = token_str[-1] if token_str and token_str[-1] in SEPARATORS and len(token_str) > 1 else None
64                is_only_sep = token_str and all(c in SEPARATORS for c in token_str)
65
66                # --- Rule handling ---
67                if not word: # 1) first token
68                    if sep_start:
69                        remainder = token_str[1:]
70                        if remainder:
71                            for tid in cyrillic_token_ids:
72                                if token_cache[tid]['str'] == remainder:
73                                    new_beams.append((new_ids, [tid], [prob], total_prob, d + 1))
74                                    break
75                        else:
76                            new_beams.append((new_ids, [token_id], [prob], total_prob, d + 1))
77                        continue
78
79                if sep_start and not is_only_sep: # 2) non-first, starts with sep
80                    save_word(word, word_probs, seq_prob, d, {sep_start}, prob)
81                    continue
82
83                if is_only_sep: # 3) only separator
84                    if word:
85                        save_word(word, word_probs, seq_prob, d, {token_str}, prob)
86                    continue
87
88                if sep_end: # 4) ends with separator
89                    part = token_str[:-1]
90                    if part:
91                        for tid in cyrillic_token_ids:
92                            if token_cache[tid]['str'] == part:
93                                new_word = word + [tid]
94                                new_probs = word_probs + [prob]
95                                save_word(new_word, new_probs, total_prob, d + 1, {sep_end}, prob)
96                                break
97                        continue
98
99                # 5) regular continuation
100                new_beams.append((new_ids, word + [token_id], word_probs + [prob], total_prob, d + 1))
101
102    beams = sorted(new_beams, key=lambda x: x[3], reverse=True)[:beam_width]
103
104    # Save unfinished words
105    for word, probs, seq_prob, d in beams:
106        if word:
107            save_word(word, probs, seq_prob, d, "достигнута максимальная глубина")
108
109    results = []
110    for w in completed_words:
111        results.append({
112            'word': w,
113            'probability': completed_words[w],
114            'token_probabilities': word_details[w]['probs'],
115            'token_count': len(word_details[w]['tokens']),
116            'depth': word_details[w]['depth'],
117            'tokens': word_details[w]['tokens'],
118            'token_texts': [token_cache[t]['str'] for t in word_details[w]['tokens']],
119            'stop_reason': word_details[w]['stop_reason'],
120            'separator_probability': word_details[w]['separator_probability']
121        })
122    return sorted(results, key=lambda x: x['probability'], reverse=True)

```